

LAPORAN AKHIR
MOBILITAS AKADEMIK STUDI INDEPENDEN
PENGEMBANGAN SISTEM OPTIMASI HARGA PRODUK UNTUK MARGIN
BERBASIS DATA MENGGUNAKAN PENDEKATAN DATA-DRIVEN PADA
PERUSAHAAN RETAIL IT

CV DB KLIK



Penyusun

Nurin Nasi'ah Salsabila

23031554148

UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI SAINS DATA

TAHUN 2026

LEMBAR PENGESAHAN

Judul Kegiatan	Pengembangan Sistem Optimasi Harga Produk Berbasis Data Menggunakan Pendekatan Data-Driven pada Perusahaan Retail IT
Nama Mitra	CV DB Klik
Alamat Instansi	Raya Tenggilis Mejoyo No.AA - 3, Kali Rungkut, Kec. Rungkut, Surabaya, Jawa Timur 60293
Identitas mahasiswa Nama NIM Prodi/Jurusan Fakultas No Tlp. Alamat Email	Nurin Nasi'ah Salsabila 23031554148 Sains Data Matematika dan Ilmu Pengetahuan Alam 081334402820 nurin.23148@unesa.ac.id
Periode Riset	25 Maret 2026 – 24 Juli 2026

Mengetahui

Dosen Pembimbing Lapangan



Dinda Galuh Guminta, M.Stat.

NIP. 99612112024062003

Mahasiswa



Nurin Nasi'ah Salsabila

NIM.23031554148

Menyetujui,

Koordinator Program Studi



Yuliani Puji Astuti, S.Si., M.Si.

NIP. 197807312006042001

DAFTAR ISI

DAFTAR ISI.....	3
DAFTAR GAMBAR.....	4
DAFTAR TABEL.....	5
BAB I.....	5
1.1 Latar Belakang.....	5
1.2 Tujuan Studi Independen	6
1.3 Manfaat Proyek/Studi Independen	7
BAB II.....	10
2.1 Tinjauan Teoritis.....	10
2.2 Penelitian Sebelumnya.....	16
2.3 Variabel-variabel yang Diteliti.....	18
2.4 Luaran Berdampak yang Diusulkan.....	20
BAB III	21
3.1 Posisi / Kedudukan Kegiatan Proyek/Studi Independen.....	21
3.2 Metodologi Penyelesaian Tugas	21
3.3 Pembelajaran Hal Baru	26
BAB IV	28
4.1 Hasil.....	28
4.2 Pembahasan.....	35
BAB V	59
5.1 Kegiatan Studi Independen yang Dikembangkan.....	59
5.2 Tujuan Pengembangan.....	59
5.3 Langkah-langkah Pengembangan	60
5.4 Relevansi dengan Mata Kuliah Konversi.....	63
BAB VI.....	72
6.1 Rencana Tindak Lanjut.....	72
6.2 Rekomendasi.....	73
BAB VII.....	75
7.1 Kesimpulan	75
7.2 Refleksi Akhir.....	75
DAFTAR PUSTAKA	77
LAMPIRAN.....	79

DAFTAR GAMBAR

Gambar 3.1 Flowchart Penyelesaian Proyek	22
Gambar 4.1 Ringkasan Integrasi dataset internal dan Kompetitor	28
Gambar 4.2 <i>Coverage</i> Hasil <i>Product Matching</i>	29
Gambar 4.3 <i>Distribusi similarity score</i>	30
Gambar 4.4 Perbandingan harga hasil <i>product matching</i>	30
Gambar 4.5 Top 10 Brand dengan Match Terbanyak	31
Gambar 4.6 Perbandingan harga hasil <i>product matching</i>	31
Gambar 4.7 Perbandingan error model.....	32
Gambar 4.8 Perbandingan error model v1 dan v2	33
Gambar 4.9 Tampilan <i>dashboard</i> looker studio.....	34
Gambar 4.10 Tampilan Dashboard Looker.....	35
Gambar 4.11 File Hasil Scraping.....	36
Gambar 4.12 Contoh Data hasil merge Scrapping dan SKU	37
Gambar 4.13 <i>Code Pre-processing</i> Nama Produk dan Harga.....	Kesalahan!
Bookmark tidak ditentukan.	
Gambar 4.14 Hasil checking brand yang tidak diketahui	40
Gambar 4.15 Stopwords dan kata yang karakter tambahan.....	41
Gambar 4.16 Distribusi similarity score	45
Gambar 4.17 Feature Importance Analysis.....	51
Gambar 4.18 Arsitektur Sistem Optimasi Harga	55
Gambar 4.19 Tampilan Dashboard Looker (Per Bulan Mei)	Kesalahan!
Bookmark tidak ditentukan.	
Gambar 4.20 Tampilan Dashboard Looker (Per Bulan Mei) (2)	57
Gambar 4.21 Tampilan Dashboard Looker (Per Bulan Mei)	57
Gambar 4.22 Alur kerja prediksi demand dan hitung profit	57
Gambar 5.1 Dokumentasi visual studio code	67
Gambar 5.2 Tampilan FastAPI	67
Gambar 5.3 Flow Diagram Sistem Simulasi Harga Berbasis Web	69
Gambar 5.4 Gambar ERD.....	70

DAFTAR TABEL

Tabel 2.1 Metode Pengukuran Kemiripan Teks.....	12
Tabel 2.2 Studi Sebelumnya yang Relevan dengan Penelitian	16
Tabel 2.3 Pengkategorian Variabel yang Digunakan	18
Tabel 4.1 Ringkasan Dataset Hasil Integrasi	29
Tabel 4.2 Total Produk di Setiap Perusahaan.....	36
Tabel 4.3 Contoh Perbedaan Sebelum dan Sesudah Normalisasi Nama Produk .	39
Tabel 4.4 Penurunan brand <i>Unknown</i>	41
Tabel 4.5 Perbedaan jumlah dataset setelah <i>brand applied</i>	41
Tabel 4.6 Aturan yang harus ada antara DB Klik dan Kompetitor supaya bisa dicocokkan dengan kode model.....	42
Tabel 4.7 Parameter TF-IDF yang digunakan.....	43
Tabel 4.8 Contoh Pembentukan N-Gram.....	44
Tabel 4.9 Kategori Fitur yang Digunakan.....	46
Tabel 4.10 Parameter Utama Random Forest Regression.....	49
Tabel 4.11 Parameter Simulasi Harga	53
Tabel 4.12 Ilustrasi Harga	53
Tabel 4.13 Hasil Simulasi Harga.....	54
Tabel 4.14 Spesifikasi Sistem	54
Table 4.15 Kegiatan Proyek dan Studi Bulan Maret	60
Table 4.16 Kegiatan Proyek dan Studi Bulan April	61
Table 4.17 Kegiatan Proyek dan Studi Bulan Mei	61
Table 4.18 Kegiatan Proyek dan Studi Bulan Juni	62
Table 4.19 Identifikasi Pengguna Sistem	68
Table 4.20 Kebutuhan Fungsional Sistem.....	68
Table 4.21 Kebutuhan Sistem Non-Fungsional	69

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi mendorong perusahaan untuk mengoptimalkan pemanfaatan data dalam pengambilan keputusan bisnis, khususnya pada sektor retail yang memiliki dinamika permintaan dan harga yang tinggi. Salah satu aspek penting dalam retail adalah penentuan harga produk yang optimal agar dapat meningkatkan daya saing dan profitabilitas. Pendekatan berbasis data (*data-driven*) menjadi solusi yang semakin banyak digunakan untuk mendukung strategi penetapan harga yang lebih adaptif dan akurat. Penelitian menunjukkan bahwa penerapan analisis data dan optimasi harga berbasis permintaan mampu meningkatkan pendapatan serta efisiensi operasional perusahaan retail (Liu & Sustik, 2021).

Namun, pada praktiknya masih banyak perusahaan yang menggunakan metode konvensional dalam menentukan harga, seperti berdasarkan intuisi atau aturan statis, sehingga kurang mampu merespons perubahan pasar secara cepat. Pemanfaatan *business analytics* dan *machine learning* dalam sektor retail terbukti dapat membantu dalam memahami pola penjualan, memprediksi permintaan, serta mendukung pengambilan keputusan yang lebih efektif (Rahman dan Hasan, 2025; Hossain, 2025). Selain itu, penggunaan data secara terstruktur juga memungkinkan perusahaan untuk mengidentifikasi peluang optimasi harga yang sebelumnya tidak terlihat melalui metode manual.

Tantangan utama dalam melakukan optimasi harga yang kompetitif adalah adanya kesulitan dalam melakukan penyelarasan data produk internal dengan data milik kompetitor secara akurat karena perbedaan penamaan atau penulisan SKU (*Stock Keeping Unit*). Untuk mengatasi masalah pencocokan teks produk (*product matching*) ini, pendekatan *Natural Language Processing* (NLP) menggunakan kombinasi Term Frequency-Inverse Document Frequency (TF-IDF) dan N-Gram terbukti efektif dalam mengekstrak fitur tekstual yang spesifik, yang kemudian diukur tingkat kemiripannya menggunakan Cosine Similarity guna memetakan kesamaan produk retail antar-platform secara akurat (Kusniyati dan Nugraha, 2020).

Setelah data kompetitor berhasil dipetakan, langkah krusial berikutnya adalah melakukan peramalan permintaan pasar dan penyesuaian harga. Penggunaan algoritma Random Forest Regression secara luas telah terbukti memiliki performa yang sangat baik dan stabil dalam memprediksi *demand forecasting* sekaligus merancang strategi *dynamic pricing* berbasis *machine learning* karena kemampuannya menangani variabel retail yang kompleks tanpa mengalami *overfitting* (Iskandar et al, 2024). Hasil dari prediksi permintaan tersebut kemudian diintegrasikan ke dalam model kalkulasi matematika guna mensimulasikan harga terbaik yang mampu memaksimalkan profit margin atau volume penjualan.

Untuk mengatasi permasalahan tersebut, diperlukan pengembangan sistem yang mampu mengolah data penjualan menjadi rekomendasi harga yang optimal melalui pendekatan *data-driven*. Sistem ini dapat mengintegrasikan proses analisis

data, optimasi harga, serta visualisasi hasil untuk mendukung pengambilan keputusan yang lebih baik. Menurut Basu et al., (2025), pemanfaatan *data analytics* dalam pengambilan keputusan bisnis mampu meningkatkan kualitas strategi perusahaan secara signifikan. Oleh karena itu, studi ini dilakukan dengan mengembangkan sistem optimasi harga berbasis data pada perusahaan retail IT, yaitu CV. DB Klik, sebagai upaya untuk meningkatkan efektivitas penentuan harga dan kinerja penjualan perusahaan.

1.2 Tujuan Studi Independen

Tujuan utama dari pelaksanaan Studi Independen ini adalah merancang, membangun, dan mengimplementasikan prototype sistem *Price Optimization* berbasis *machine learning* dan *business analytics* di CV DB Klik. Proyek ini bertujuan untuk mentransformasi metode penetapan harga konvensional menjadi strategi penentuan harga yang tangkas, kompetitif, dan berbasis data (*data-driven pricing strategy*). Secara lebih spesifik dan luas, tujuan dari proyek ini dijabarkan ke dalam poin-poin berikut:

- Mengotomatisasi Proses Pengumpulan Data Pasar (*Data Acquisition & Crawling*): Membangun mekanisme penarikan data secara berkala (per pekan) untuk mengambil data harga dari e-commerce kompetitor serta mengekstrak data internal (HPP, SKU, dan penjualan mingguan) dari portal resmi dan sell center CV DB Klik secara terintegrasi.
- Menyelesaikan Hambatan Ketidakselarasan Data Produk (*Product Matching*): Menerapkan teknik *Natural Language Processing (NLP)* melalui kombinasi *TF-IDF* dan *N-Gram* yang diukur menggunakan *Cosine Similarity* untuk mengatasi perbedaan penamaan SKU antar-platform, sehingga proses komparasi harga produk internal dengan kompetitor dapat berjalan akurat secara otomatis (Kusniyati dan Nugraha, 2020).
- Membangun Model Peramalan Permintaan Pasar (*Demand Forecasting*): Mengembangkan dan melatih (training) model machine learning dengan algoritma Random Forest Regression setelah melalui tahapan feature engineering dan agregasi data. Model ini bertujuan untuk memprediksi volume permintaan produk berdasarkan tren historis, harga kompetitor, dan fluktuasi pasar retail (Jurnal Ilmiah, 2024).
- Merumuskan Operasi Optimasi Harga Berbasis Prediksi Permintaan: Mengintegrasikan output dari model prediksi demand ke dalam formula kalkulasi matematika guna mensimulasikan berbagai skenario harga. Hal ini bertujuan untuk mengidentifikasi titik harga optimal yang mampu memaksimalkan profit margin tanpa mengorbankan daya saing produk di pasar.
- Menyediakan Platform Analitik Visual (*Dashboarding*): Menyajikan hasil pemodelan, tren penjualan, dan analisis performa produk ke dalam *Dashboard* Looker Studio yang interaktif, guna memudahkan pihak manajemen CV DB Klik dalam membaca pola bisnis dan mengambil keputusan taktis secara cepat.
- Mengembangkan dan Mengimplementasikan Sistem Aplikasi Web (*Deployment*): Membangun antarmuka (interface) web kustom berbasis HTML, CSS, dan JSON yang mengintegrasikan *dashboard* analitik sekaligus menyediakan fitur simulasi harga produk secara mandiri. Aplikasi web ini kemudian di-deploy menggunakan layanan Netlify/Vercel agar dapat diakses secara publik dan stabil oleh pemangku kepentingan.

1.3 Manfaat Proyek/Studi Independen

Pelaksanaan proyek pengembangan sistem *Price Optimization* berbasis *machine learning* ini diharapkan dapat memberikan kontribusi yang signifikan baik dari aspek akademis, industri, maupun pengembangan kompetensi mahasiswa. Adapun manfaat yang diperoleh dari pelaksanaan studi independen ini dijabarkan sebagai berikut:

1.3.1 Bagi Pengetahuan Akademis dan Riset

- Implementasi Praktis Teori Data Science, Proyek ini diharapkan dapat menjadi salah satu referensi implementasi nyata dari berbagai konsep dan metode dalam bidang Data Science, khususnya pada integrasi metode *Natural Language Processing* (NLP) seperti *Term Frequency-Inverse Document Frequency* (TF-IDF), *N-Gram*, dan *Cosine Similarity*, serta metode *Predictive Analytics* menggunakan algoritma *Random Forest Regression*. Implementasi tersebut dilakukan dalam konteks penyelesaian permasalahan bisnis ritel elektronik yang kompleks, sehingga dapat memperkaya kajian akademis terkait penerapan teknologi kecerdasan buatan dan analitik data pada lingkungan industri nyata.
- Pengayaan Studi Strategi Penetapan Harga Berbasis Data, Proyek ini diharapkan dapat memberikan kontribusi terhadap pengembangan literatur ilmiah terkait strategi penetapan harga (*pricing strategy*) berbasis data (*data-driven pricing*). Melalui integrasi model prediksi permintaan (*demand forecasting*) dan mekanisme optimasi harga, penelitian ini dapat memberikan gambaran mengenai bagaimana hasil prediksi permintaan dapat dimanfaatkan untuk menghasilkan rekomendasi harga yang optimal, adaptif, dan sesuai dengan dinamika pasar. Selain itu, proyek ini juga diharapkan dapat menjadi referensi dalam pengembangan sistem pendukung keputusan (*Decision Support System*) pada bidang manajemen dan analitik bisnis.

1.3.2 Bagi Praktisi Lapangan dan Industri (Mitra CV DB Klik)

- Peningkatan Efisiensi dan Akurasi Penetapan Harga, Proyek ini diharapkan dapat membantu pihak manajemen CV DB Klik dalam melakukan transformasi dari proses penentuan harga yang masih bersifat konvensional, manual, atau berbasis intuisi, menuju sistem penetapan harga yang lebih terstruktur, otomatis, dan berbasis data. Dengan memanfaatkan analisis historis penjualan, informasi harga kompetitor, serta prediksi permintaan pasar, sistem yang dikembangkan diharapkan mampu menghasilkan rekomendasi harga yang lebih akurat dan responsif terhadap perubahan kondisi pasar.
- Peningkatan Daya Saing dan Profitabilitas Perusahaan, Sistem *Price Optimization* yang dikembangkan diharapkan dapat menjadi alat bantu strategis bagi perusahaan dalam menentukan kebijakan harga yang kompetitif. Melalui kemampuan simulasi berbagai skenario harga, perusahaan dapat memperoleh estimasi dampak perubahan harga terhadap tingkat permintaan, volume penjualan, serta potensi keuntungan yang dihasilkan. Dengan demikian, perusahaan diharapkan mampu meminimalkan risiko penurunan margin keuntungan (*loss margin*),

meningkatkan efisiensi pengambilan keputusan, serta memperkuat daya saing di industri ritel elektronik.

- Peningkatan Transparansi dan Visualisasi Kinerja Bisnis, Pengembangan dashboard analitik menggunakan platform Looker diharapkan dapat memberikan kemudahan bagi stakeholder internal perusahaan dalam melakukan pemantauan performa bisnis secara visual, interaktif, dan real-time. Dashboard tersebut dapat dimanfaatkan untuk memonitor berbagai indikator kinerja utama (*Key Performance Indicators/KPI*), seperti performa produk, tren penjualan, perbandingan harga kompetitor, serta estimasi permintaan pasar, sehingga mendukung proses pengambilan keputusan yang lebih cepat dan berbasis data.

1.3.3 Bagi Keterampilan Pribadi dan Profesional Mahasiswa

- Pengembangan Kompetensi Teknis (*Hard Skills*), Pelaksanaan studi independen ini diharapkan dapat meningkatkan kemampuan teknis mahasiswa dalam berbagai bidang yang relevan dengan industri Data Science modern. Kompetensi tersebut meliputi proses pengumpulan data (*data crawling* dan *web scraping*), pembersihan dan transformasi data, penggabungan dataset (*data merging*), rekayasa fitur (*feature engineering*), pengembangan model *machine learning*, evaluasi model prediktif, implementasi *Natural Language Processing*, visualisasi data menggunakan *Business Intelligence Tools*, hingga proses pengembangan dan *deployment* aplikasi berbasis web menggunakan teknologi HTML, CSS, JSON, serta platform *cloud deployment* seperti Netlify dan Vercel.
- Penguatan Kemampuan Analitis dan Penyelesaian Masalah (*Soft Skills*), Selain kompetensi teknis, pelaksanaan proyek ini juga diharapkan dapat mengembangkan kemampuan berpikir kritis (*critical thinking*), pemecahan masalah (*problem solving*), komunikasi, serta pengambilan keputusan berbasis data. Mahasiswa dilatih untuk mampu mengidentifikasi permasalahan bisnis yang kompleks, menerjemahkan kebutuhan industri menjadi solusi teknologi yang implementatif, serta mengevaluasi efektivitas solusi yang dikembangkan melalui pendekatan ilmiah dan analitis.
- Peningkatan Kesiapan Karier di Dunia Industri, Melalui keterlibatan langsung dalam proyek yang merepresentasikan kebutuhan industri nyata, mahasiswa diharapkan memperoleh pengalaman praktis yang mencerminkan alur kerja (*end-to-end pipeline*) seorang profesional di bidang Data Analyst, Business Intelligence Analyst, maupun Data Scientist. Pengalaman tersebut mencakup proses identifikasi kebutuhan bisnis, pengolahan data, pembangunan model analitik, visualisasi informasi, hingga implementasi sistem pendukung keputusan, sehingga dapat meningkatkan kesiapan mahasiswa dalam menghadapi tantangan dunia kerja profesional.

BAB II

TINJAUAN PUSTAKA

2.1 Tinjauan Teoritis

Dalam melakukan transformasi strategi bisnis yang awalnya menggunakan metode konvensional lalu beralih menggunakan metode berbasis data, diperlukan landasan teori yang kuat mengenai integrasi pengolahan data tekstual, pemodelan prediktif, dan optimasi matematis. Berikut penjelasan konsep utama dan kerangka teoritis yang menjadi dasar pengembangan sistem analisis harga:

2.1.1 Teori-Teori Utama

2.1.1.1 Strategi Penetapan Harga Berbasis Data

Penetapan harga konvensional yang hanya menggunakan intuisi atau perhitungan biaya produksi ditambah margin tetap sering kali kurang cocok untuk merespons perubahan pasar retail yang selalu berubah. Strategi penetapan harga modern memanfaatkan *business analytics* dan *machine learning* untuk memahami pola penjualan serta mengidentifikasi peluang optimasi harga secara objektif (Hossain, 2025). Menurut Liu & Sustik (2021), pendekatan *data-driven pricing* terbukti mampu meningkatkan efisiensi operasional dan pendapatan perusahaan melalui adaptasi harga yang akurat berdasarkan perilaku pasar, harga kompetitor, dan elastisitas permintaan.

2.1.1.2 Pengukuran Kemiripan Teks (*Text Similarity*) Menggunakan TF-IDF, N-Gram, dan Cosine Similarity

Dalam ekosistem data retail, proses pencocokan produk (*product matching*) antarplatform merupakan salah satu tantangan utama akibat variasi penulisan nama produk dan SKU (*Stock Keeping Unit*) pada setiap sumber data. Perbedaan format, penggunaan singkatan, serta inkonsistensi penamaan menyebabkan proses identifikasi produk yang identik menjadi kompleks. Oleh karena itu, penelitian ini mengimplementasikan pendekatan *Natural Language Processing* (NLP) melalui tiga tahapan terintegrasi untuk meningkatkan akurasi pencocokan data produk.

2.1.1.3 Domain-Driven Feature Engineering

Domain-driven feature engineering merupakan proses pembentukan fitur baru berdasarkan pengetahuan dan pemahaman terhadap domain permasalahan tertentu. Dalam konteks retail dan optimasi harga, pendekatan ini bertujuan untuk menghasilkan fitur yang mampu merepresentasikan pola historis penjualan, kondisi kompetitif pasar, serta aspek profitabilitas bisnis yang tidak dapat ditangkap secara langsung oleh data mentah (Phillips, 2005). Pada penelitian ini, proses feature engineering dikelompokkan ke dalam tiga kategori utama, yaitu:

2.1.1.3.1 Temporal Features

Temporal features merupakan fitur yang dibentuk berdasarkan informasi waktu untuk menangkap pola historis, tren, dan ketergantungan temporal pada data penjualan (Hyndman &

Athanasopoulos, 2021). Fitur ini digunakan untuk membantu model memahami hubungan antara perilaku penjualan pada periode sebelumnya dengan permintaan pada periode saat ini.

2.1.1.3.1.2 Competitive Features

Competitive features merupakan fitur yang dibentuk untuk merepresentasikan posisi harga suatu produk terhadap kondisi pasar dan harga kompetitor. Fitur ini digunakan untuk mengukur tingkat daya saing harga yang berpotensi memengaruhi perilaku pembelian konsumen dan volume permintaan (Phillips, 2005).

2.1.1.3.1.3 Business/Financial Features

Business/financial features merupakan fitur yang dibentuk berdasarkan aspek bisnis dan profitabilitas perusahaan. Fitur ini digunakan untuk memastikan bahwa proses prediksi dan optimasi harga tetap mempertimbangkan batas keuntungan yang diharapkan perusahaan (Talluri & Van Ryzin, 2004).

2.1.1.4 Demand Forecasting Berbasis Random Forest Regression

Random Forest Regression dipilih dalam penelitian ini karena memiliki kemampuan yang baik dalam menangani karakteristik data retail yang kompleks, seperti hubungan non-linear antara variabel harga, permintaan, waktu, dan faktor eksternal lainnya. Selain itu, algoritma ini tidak memerlukan asumsi distribusi data tertentu, mampu mengakomodasi interaksi antarvariabel secara otomatis, serta memiliki ketahanan yang tinggi terhadap *overfitting* akibat mekanisme randomisasi dan agregasi yang diterapkan pada proses pembentukan model (Breiman, 2001; Schonlau & Zou, 2020).

Keunggulan lain dari Random Forest Regression adalah kemampuannya dalam menangani data berdimensi tinggi, mengidentifikasi variabel yang paling berpengaruh melalui *feature importance*, serta mempertahankan performa prediksi yang stabil meskipun terdapat variabel yang saling berkorelasi atau mengandung *noise* (Scornet et al., 2015). Karakteristik tersebut menjadikan Random Forest sebagai salah satu algoritma yang banyak digunakan pada bidang *predictive analytics*, khususnya dalam kasus peramalan permintaan (*demand forecasting*), analisis perilaku konsumen, serta pengambilan keputusan berbasis data pada sektor retail dan bisnis.

2.1.1.5 Operasi Optimasi Harga Berbasis Demand Forecasting

Operasi optimasi harga berada pada domain *prescriptive analytics*, di mana hasil prediksi volume permintaan (output dari model Random Forest) diintegrasikan ke dalam fungsi kalkulasi matematika (Liu & Sustik, 2021). Pendekatan ini tidak hanya berfokus pada proses prediksi, tetapi juga menghasilkan rekomendasi keputusan yang dapat diterapkan untuk mencapai

tujuan bisnis tertentu. Dalam konteks retail, hasil estimasi permintaan digunakan sebagai dasar untuk melakukan simulasi berbagai skenario penetapan harga sehingga perusahaan dapat menentukan strategi harga yang lebih adaptif dan berbasis data.

Model optimasi ini mensimulasikan titik harga terbaik (*sweet spot price*) dengan mempertimbangkan variabel modal atau Harga Pokok Penjualan (HPP) serta batas harga pasar yang ditetapkan oleh kompetitor (Jurnal Ilmiah, 2024). Tujuan utama dari integrasi formula matematis ini adalah mencari keseimbangan harga yang dapat memaksimalkan profitabilitas bersih tanpa menurunkan volume penjualan akibat harga yang terlalu tinggi (Liu & Sustik, 2021). Melalui pendekatan ini, perusahaan dapat mengevaluasi berbagai alternatif harga, memahami sensitivitas pasar terhadap perubahan harga, serta mendukung proses pengambilan keputusan yang lebih objektif, efisien, dan kompetitif.

2.1.2 Model atau Framework yang Digunakan

Pengembangan sistem *Price Optimization* berbasis *machine learning* memerlukan integrasi berbagai metode dan framework untuk mendukung proses analisis data, pencocokan produk, prediksi permintaan, optimasi harga, serta visualisasi informasi. Oleh karena itu, penelitian ini memanfaatkan beberapa teknologi yang relevan pada bidang *Natural Language Processing* (NLP), *Machine Learning*, *Predictive Analytics*, *Business Intelligence*, dan *Web Development*. Adapun model dan framework yang digunakan dalam pengembangan sistem dijelaskan pada tabel berikut.

Tabel 2.1 Metode Pengukuran Kemiripan Teks

Model/Framework	Kategori	Pengenalan Singkat dan Penggunaan
<i>TF-IDF (Term Frequency - Inverse Document Frequency)</i>	Pendekatan <i>Natural Language Processing</i> (NLP)	Algoritma statistik yang digunakan untuk mengukur seberapa penting suatu kata dalam sebuah kumpulan dokumen atau teks nama produk (Kusniyati dan Nugraha, 2020). TF (Term Frequency), Menghitung seberapa sering sebuah kata (term) muncul dalam satu dokumen (nama produk). $TF(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}}$ Keterangan: $f_{t,d}$ adalah frekuensi kemunculan kata t pada dokumen d, dan penyebutnya adalah total seluruh kata dalam dokumen tersebut. IDF (Inverse Document Frequency), Mengukur seberapa penting atau langka kata tersebut di dalam seluruh kumpulan data (corpus).

$$IDF(t, D) = \log \left(\frac{N}{1 + |\{d \in D : t \in d\}|} \right)$$

Keterangan: N adalah total seluruh baris produk/dokumen dalam dataset, dan $|\{d \in D : t \in d\}|$ adalah jumlah dokumen yang mengandung kata t (ditambah 1 untuk menghindari pembagian dengan nol).

Rumus perhitungan TF-IDF:

$$W_{t,d} = TF(t, d) \times IDF(t, D)$$

<i>N-Gram</i>	Pendekatan <i>Natural Language Processing</i> (NLP)	Metode pemotongan rangkaian kata menjadi n-karakter/kata yang berurutan untuk menangkap pola penulisan tipe, ukuran, atau kode unik produk retail yang spesifik (Kusniyati dan Nugraha, 2020). Jika sebuah nama produk dinyatakan sebagai baris kata $S = \{w_1, w_2, w_3, \dots, w_m\}$, maka pemotongan elemennya adalah: • Bi-gram ($n = 2$): Pemotongan per dua karakter/kata berturut-turut: Bi-gram(S) $= \{(w_1, w_2), (w_2, w_3), (w_3, w_4), \dots, (w_{m-1}, w_m)\}$ • Tri-gram ($n = 3$): Pemotongan per tiga karakter/kata berturut-turut: Tri-gram(S) $= \{(w_1, w_2, w_3), (w_2, w_3, w_4), \dots, (w_{m-2}, w_{m-1}, w_m)\}$ <i>Contoh Kasus:</i> Kata "SSD" jika dipecah menggunakan karakter-level Bi-gram akan menjadi sekumpulan token: {'SS', 'SD'}.
<i>Cosine Similarity</i>	Pendekatan <i>Natural Language Processing</i> (NLP)	Metrik yang digunakan untuk mengukur derajat kemiripan antara dua vektor teks nama produk dengan cara menghitung sudut kosinus di antara keduanya (Kusniyati dan Nugraha, 2020). Jika nilai <i>similarity</i> mendekati 1, maka kedua produk tersebut diidentifikasi sebagai produk yang sama (identik) meskipun ditulis dengan format berbeda.

$$\text{Cosine Similarity}(\vec{A}, \vec{B}) = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \|\vec{B}\|}$$

$$= \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \times \sqrt{\sum_{i=1}^n B_i^2}}$$

Keterangan: > * $\vec{A}$ = Vektor bobot TF-IDF produk dari internal CV DB Klik.

- $\vec{B}$ = Vektor bobot TF-IDF produk dari hasil scraping kompetitor.
- Nilai akhir berkisar antara 0 (tidak mirip sama sekali) hingga 1 (produk identik/sama persis).

<i>Lag Features, Rolling Mean & Price Change</i>	Feature Engineer (Temporal)	Lag Feature - fitur yang menggeser nilai penjualan ke masa lalu (misalnya penjualan $t-1$ atau $t-2$ pekan lalu) untuk menangkap efek ketergantungan waktu (<i>temporal dependency</i>) pada perilaku konsumen. Rolling Mean - Perhitungan rata-rata bergerak dari volume penjualan dalam jendela waktu tertentu (misalnya rata-rata 4 pekan terakhir) guna menghaluskan fluktuasi jangka pendek (<i>noise</i>) dan menangkap tren penjualan secara umum. <i>Price Change</i> - merupakan fitur yang digunakan untuk mengukur frekuensi maupun besarnya perubahan harga suatu produk dari waktu ke waktu. Dalam konteks retail, perubahan harga historis sering digunakan sebagai variabel penting dalam pemodelan permintaan karena berkaitan erat dengan persepsi nilai dan sensitivitas konsumen terhadap harga (Talluri & Van Ryzin, 2004).
<i>Price Gap & Price Ratio</i>	Feature Engineer (Competitive)	Price Gap merupakan selisih <i>absolut</i> antara harga produk internal dengan harga produk kompetitor (<i>Harga Internal - Harga Kompetitor</i>). Fitur ini berfungsi sebagai indikator tingkat kompetitivitas harga suatu produk di pasar. Sementara itu, Price Ratio merupakan rasio perbandingan antara harga produk internal dan harga kompetitor (<i>Harga Internal/Harga Kompetitor</i>), yang digunakan untuk mengukur posisi relatif harga produk terhadap harga pasar.

<i>Margin Feature</i>	Feature Engineer (Business/Finansial)	<i>Margin Feature</i> merupakan fitur yang diperoleh dari selisih antara harga jual dengan Harga Pokok Penjualan (HPP). Dengan memasukkan informasi margin ke dalam model, sistem dapat menghasilkan rekomendasi harga yang tidak hanya kompetitif di pasar, tetapi juga tetap menjaga keberlanjutan keuntungan bisnis (Phillips, 2005).
<i>Random Forest Regression</i>	<i>Machine Learning</i>	Random Forest Regression merupakan salah satu metode <i>ensemble learning</i> berbasis <i>decision tree</i> yang bekerja dengan membangun sejumlah besar pohon keputusan (<i>decision trees</i>) melalui proses <i>bootstrap aggregating (bagging)</i> dan pemilihan subset fitur secara acak pada setiap node pemisahan (Breiman, 2001). Prediksi akhir pada permasalahan regresi diperoleh melalui proses agregasi berupa rata-rata hasil prediksi dari seluruh pohon yang terbentuk, sehingga mampu menghasilkan model yang lebih stabil dan memiliki kemampuan generalisasi yang tinggi dibandingkan model pohon keputusan tunggal.
<i>FastAPI</i>	<i>Backend Development</i>	sebuah <i>web framework</i> modern berbasis bahasa pemrograman Python yang dirancang untuk membangun <i>Application Programming Interface (API)</i> dengan performa tinggi dan efisien. Framework ini mendukung pengembangan layanan <i>backend</i> yang cepat melalui fitur validasi data otomatis, dokumentasi API interaktif, serta kemampuan pemrosesan asinkron (<i>asynchronous processing</i>) (Ramírez, 2021).
<i>Chart.js</i>	<i>Library untuk Backend Development</i>	Pustaka (<i>library</i>) visualisasi data berbasis JavaScript yang digunakan untuk menampilkan berbagai jenis grafik secara interaktif pada halaman web. Library ini mendukung visualisasi seperti grafik batang, garis, pie, dan area chart dengan implementasi yang ringan serta mudah diintegrasikan dengan aplikasi berbasis web (Chart.js Documentation, 2024).
<i>Looker Studio</i>	<i>Framework</i>	platform <i>Business Intelligence (BI)</i> dan visualisasi data yang dikembangkan oleh Google untuk membuat dashboard analitik interaktif. Platform ini memungkinkan integrasi berbagai sumber data serta penyajian informasi dalam bentuk visual yang mudah dipahami oleh pengguna bisnis (Google, 2024)
<i>Netlify</i>	<i>Framework Development</i>	platform <i>cloud deployment</i> yang menyediakan layanan hosting dan <i>continuous deployment</i> untuk aplikasi web statis maupun modern. Platform ini memungkinkan proses <i>deployment</i> aplikasi dilakukan secara otomatis, cepat, dan

terintegrasi dengan sistem kontrol versi seperti GitHub (Netlify Documentation, 2024).

2.2 Penelitian Sebelumnya

- Studi Sebelumnya

Studi tentang optimalisasi harga dan analisis prediktif dalam sektor ritel telah banyak dilakukan dengan memanfaatkan berbagai metode kecerdasan buatan dan pembelajaran mesin. Beberapa kajian sebelumnya yang berkaitan dengan pengembangan sistem Price Optimization dalam penelitian ini diringkas pada Tabel 2.2.

Tabel 2.2 Studi Sebelumnya yang Relevan dengan Penelitian

Peneliti	Fokus Penelitian	Hasil Penelitian	Keterkaitan dengan Penelitian
Kusniyati dan Nugraha (2020)	<i>Product Matching</i> menggunakan pendekatan NLP	Kusniyati dan Nugraha (2020) melakukan studi mengenai penyeselarasan produk (<i>product matching</i>) antar-platform e-commerce menggunakan teknik NLP. Hasil penelitian menunjukkan bahwa kombinasi <i>Term Frequency-Inverse Document Frequency</i> (TF-IDF), <i>N-Gram</i> , dan <i>Cosine Similarity</i> sangat efektif untuk mengatasi inkonsistensi penamaan SKU produk di pasar digital dengan akurasi pemetaan yang tinggi.	Penelitian ini menjadi dasar dalam pengembangan modul <i>product matching</i> untuk menyesuaikan data produk internal dan produk kompetitor pada sistem yang dikembangkan.
Hossain (2025)	<i>Business Analytics</i> dan <i>Demand Forecasting</i>	Hossain (2025) menegaskan bahwa pemanfaatan <i>business analytics</i> dan <i>machine learning pipeline</i> mampu menangani data non-linear e-commerce secara masif untuk memahami pola musiman retail serta tren perilaku konsumen global.	Penelitian ini mendukung penggunaan pendekatan <i>predictive analytics</i> untuk memprediksi permintaan produk berdasarkan karakteristik pasar retail.
Jurnal Ilmiah (2024)	<i>Demand Forecasting</i> menggunakan <i>Random Forest Regression</i>	Studi dari Jurnal Ilmiah (2024) membuktikan bahwa algoritma <i>Random Forest Regression</i> memiliki performa dan stabilitas yang sangat	Hasil penelitian tersebut menjadi landasan pemilihan algoritma <i>Random Forest Regression</i> sebagai model

			unggul dalam melakukan <i>demand forecasting</i> dan menyusun arsitektur <i>dynamic pricing</i> berbasis data tanpa risiko mengalami gejala <i>overfitting</i> .	prediksi permintaan dalam sistem <i>Price Optimization</i> .
Liu & Sustik (2021)	Sistem Preskriptif Optimasi Harga	Liu & Sustik (2021)	berhasil memodelkan bagaimana hasil peramalan permintaan (<i>demand forecasting</i>) dapat diintegrasikan secara matematis dengan variabel Harga Pokok Penjualan (HPP) dan pergerakan kompetitor guna menghasilkan skenario penetapan harga yang memaksimalkan pendapatan sekaligus menjaga efisiensi operasional pasar retail.	Penelitian ini menjadi dasar dalam pengembangan mekanisme optimasi harga berbasis estimasi permintaan dan kondisi pasar kompetitif.

○ Kritik Terhadap Penelitian Sebelumnya

Meskipun penelitian-penelitian di atas memberikan kontribusi teori dan algoritma yang kuat, terdapat beberapa celah (*gap*) mendasar yang belum diselesaikan secara menyeluruh, seperti contoh:

▪ Perihal Isolasi Sistem

Penelitian sebelumnya cenderung membahas setiap metodologi secara terpisah dan belum mengintegrasikan seluruh proses bisnis retail ke dalam satu sistem yang utuh. Sebagai contoh, Kusniyati dan Nugraha (2020) berfokus pada permasalahan pencocokan produk (*product matching*) menggunakan pendekatan *Natural Language Processing* tanpa melanjutkan hasil penyelarasan tersebut ke tahap analisis prediktif atau pengambilan keputusan bisnis. Di sisi lain, Jurnal Ilmiah (2024) secara langsung menerapkan metode *demand forecasting* dengan asumsi bahwa data produk internal dan data kompetitor telah melalui proses pembersihan dan penyelarasan secara sempurna. Pendekatan yang terisolasi ini menyebabkan setiap tahapan analisis bekerja secara independen sehingga belum mampu menggambarkan kompleksitas proses bisnis retail secara menyeluruh.

▪ Keterbatasan Implementasi Proyek

Mayoritas studi terdahulu (seperti Liu & Sustik, 2021; Hossain, 2025) hanya berhenti pada tahap eksperimen model di lingkungan pengembangan lokal, seperti *Jupyter Notebook*, atau

pada analisis statistik dan matematis secara teoretis, tanpa melanjutkan hasil penelitian tersebut ke dalam bentuk sistem yang dapat digunakan secara langsung oleh pengguna akhir. Pendekatan ini menyebabkan hasil penelitian sulit diadopsi dalam lingkungan bisnis nyata karena memerlukan pemahaman teknis yang tinggi untuk mengoperasikan model, melakukan interpretasi hasil, maupun menjalankan simulasi pengambilan keputusan.

Padahal, dalam konteks industri retail, pengguna utama sistem pendukung keputusan sering kali berasal dari kalangan manajemen atau praktisi bisnis yang tidak memiliki latar belakang teknis di bidang pemrograman maupun *machine learning*. Oleh karena itu, diperlukan pengembangan antarmuka pengguna (*user interface*) yang intuitif, interaktif, dan mudah diakses untuk menjembatani hasil analisis data dengan proses pengambilan keputusan bisnis. Penelitian ini berupaya mengatasi keterbatasan tersebut dengan mengintegrasikan model *product matching*, *demand forecasting*, dan *price optimization* ke dalam sebuah aplikasi berbasis web yang dilengkapi dengan dashboard visual dan fitur simulasi harga yang dapat digunakan secara langsung oleh pengguna non-teknis.

- Analisis Tren Terkini

Perkembangan terkini dalam bidang analitik retail menunjukkan adanya pergeseran dari pendekatan *descriptive analytics* menuju *predictive analytics* dan *prescriptive analytics* berbasis kecerdasan buatan. Perusahaan retail modern mulai memanfaatkan teknologi *machine learning* untuk melakukan *demand forecasting*, analisis perilaku konsumen, serta penerapan strategi *dynamic pricing* yang mampu beradaptasi terhadap perubahan kondisi pasar secara real-time (Hossain, 2025; Liu & Sustik, 2021). Selain itu, integrasi metode *Natural Language Processing* (NLP) untuk *product matching* juga semakin banyak digunakan guna mengatasi permasalahan inkonsistensi data produk pada platform e-commerce dan marketplace.

Di sisi implementasi, tren pengembangan sistem analitik saat ini tidak lagi berfokus hanya pada pembangunan model prediktif, tetapi juga pada integrasi model tersebut ke dalam *Decision Support System* (DSS) yang dilengkapi dengan *Business Intelligence dashboard*, visualisasi interaktif, dan antarmuka pengguna berbasis web. Pendekatan ini memungkinkan hasil analisis dan rekomendasi yang dihasilkan oleh model *machine learning* dapat dimanfaatkan secara langsung oleh praktisi bisnis dalam proses pengambilan keputusan yang lebih cepat, akurat, dan berbasis data.

2.3 Variabel-variabel yang Diteliti

2.3.1 Definisi Operasional Variabel

Penelitian kuantitatif dalam pengembangan sistem *Price Optimization* ini melibatkan beberapa variabel operasional yang ditranslasikan dari data mentah retail menjadi matriks terukur. Definisi operasional dari masing-masing variabel dijelaskan dalam tabel berikut:

Tabel 2.3 Pengkategorian Varibel yang Digunakan

Kategori Varibel	Nama Variabel	Definisi Operasional
------------------	---------------	----------------------

Variabel Dependen (Y)	Volume (Demand/Qty)	Permintaan	Jumlah total unit produk (SKU) yang berhasil terjual dalam kurun waktu satu pekan.
Variabel Independen (X)	Harga (<i>P</i> _{komp})	Kompetitor	Rata-rata nilai nominal harga jual untuk produk yang identik (hasil <i>matching</i>) pada platform kompetitor.
	Harga (<i>P</i> _{komp})	Kompetitor	Rata-rata nilai nominal harga jual untuk produk yang identik (hasil <i>matching</i>) pada platform kompetitor.
	Selisih Harga (<i>Price Gap</i>)		Jarak absolut antara harga internal dengan harga kompetitor
	Rasio Harga (<i>Price Ratio</i>)		Perbandingan relatif harga internal terhadap kompetitor.
	Penjualan Historis (<i>Lag Volume</i>)		Volume penjualan produk pada 1 hingga 2 pekan sebelumnya ($t-1, t-2$) untuk melihat tren pasca-perubahan harga.
Variabel Kendala/Batasan	Harga Pokok (HPP)	Penjualan	Nilai modal atau biaya logistik dasar per unit produk sebagai batas bawah toleransi penurunan harga.

2.3.2 Hubungan antar Variabel

- Hubungan Harga Internal terhadap Volume Permintaan (*Price Elasticity*)
Berdasarkan hukum permintaan dalam ekonomi retail, terdapat hubungan negatif (berbanding terbalik) antara Harga Produk Internal dengan Volume Permintaan. Ketika harga internal dinaikkan, volume permintaan cenderung mengalami penurunan, dan sebaliknya (Hossain, 2025). Elastisitas ini dipelajari oleh algoritma *Random Forest* untuk memprediksi seberapa sensitif konsumen terhadap perubahan harga.
- Pengaruh Harga Kompetitor terhadap Pola Permintaan
Di pasar retail IT yang sangat kompetitif, volume permintaan tidak hanya dipengaruhi oleh harga internal, melainkan oleh posisi harga relatif terhadap pasar. Hubungan ini diukur melalui variabel *Price Gap* dan *Price Ratio*. Jika *Price Gap* bernilai positif (harga kita lebih mahal dari kompetitor), probabilitas penurunan permintaan akan meningkat karena konsumen cenderung beralih ke kompetitor (Liu & Sustik, 2021).
- Pengaruh Penjualan Historis (*Lag Features*) terhadap Permintaan
Volume penjualan pada pekan sebelumnya (*Lag Volume*) memiliki hubungan positif yang signifikan terhadap prediksi permintaan pekan berjalan. Pola historis ini mencerminkan kontinuitas tren pasar, loyalitas konsumen, atau siklus hidup (*product life cycle*) dari suatu SKU IT di pasar (Ferreira dkk., 2016).
- Integrasi Variabel dalam Operasi Optimasi
Variabel HPP dan Harga Kompetitor bertindak sebagai variabel kendala (*constraints*) dalam formula optimasi matematika. Hubungan ini bersifat preskriptif: formulasi optimasi mencari titik temu di mana Harga Internal menghasilkan volume permintaan terbaik (berdasarkan prediksi *Random Forest*), namun tetap berada di atas nilai HPP (untuk menjamin margin) dan tetap kompetitif terhadap harga pasar kompetitor (Liu & Sustik, 2021).

2.4 Luaran Berdampak yang Diusulkan

Dalam pelaksanaan studi independen di divisi *Data Analyst* pada CV DB Klik, luaran yang diusulkan dirancang untuk memberikan kontribusi nyata yang bersifat solutif dan dapat diimplementasikan langsung. Luaran ini mengintegrasikan pemodelan data prediktif ke dalam sebuah sistem aplikasi praktis guna menjawab kebutuhan bisnis mitra.

- Luaran yang dihasilkan : sebuah *Prototype Sistem Price Optimization* berbasis *machine learning* terpadu. Sistem ini mengintegrasikan data penjualan, data SKU, data HPP internal, dan data harga kompetitor hasil *scraping* ke dalam satu platform analitik. Platform ini dilengkapi dengan fitur visualisasi data operasional melalui Dashboard Looker Studio serta modul simulasi dan rekomendasi harga dinamis (*dynamic pricing*) menggunakan algoritma Random Forest Regression yang dibungkus dalam antarmuka web kustom berbasis HTML, CSS, dan JSON.
- Dampak nyata bagi mitra CV DB Klik :
 1. Dampak Finansial

Mentransformasi metode penetapan harga dari pendekatan konvensional yang berbasis intuisi dan pengalaman menjadi pendekatan berbasis data (*data-driven decision making*). Transformasi ini memungkinkan perusahaan untuk memanfaatkan analisis historis penjualan, kondisi pasar, dan perilaku konsumen sebagai dasar dalam menentukan strategi harga yang lebih objektif dan terukur. Dengan demikian, manajemen dapat mengambil keputusan penetapan harga yang lebih efektif, mengoptimalkan margin keuntungan (*profitability*), meningkatkan daya saing produk IT di pasar e-commerce, serta meminimalkan risiko kerugian akibat penetapan harga yang kurang sesuai dengan kondisi pasar.
 2. Dampak Non-finansial

Menyediakan alat simulator interaktif yang memungkinkan pengguna (tim internal/manajemen) memilih produk tertentu dan melakukan simulasi perubahan harga guna melihat estimasi volume permintaan (*demand forecasting*) serta tingkat kesesuaian harga produk dengan kondisi pasar terkini.
- Mitra Strategis: Divisi IT / *Data Analyst Team*, *Online Team*, dan Operasional CV DB Klik.

BAB III METODE

3.1 Posisi / Kedudukan Kegiatan Proyek/Studi Independen

Dalam pelaksanaan kegiatan Studi Independen di CV DB Klik, mahasiswa ditempatkan pada jabatan *Data Analyst* di bawah supervisi Divisi Teknologi Informasi (IT). Dalam posisi ini, mahasiswa memiliki tugas untuk membantu proses pengambilan keputusan bisnis yang didasarkan pada data melalui pemrosesan, analisis, visualisasi, serta pembuatan model prediktif yang berkaitan dengan operasi dan strategi perusahaan.


Secara spesifik, mahasiswa berkontribusi dalam proyek pengembangan sistem *Price Optimization* untuk produk retail IT yang bertujuan mendukung perusahaan dalam menetapkan strategi harga yang lebih kompetitif dan berbasis data (*data-driven decision making*). Dalam proyek ini, mahasiswa bertugas untuk melakukan *product matching* antara data produk internal perusahaan dan data produk dari kompetitor dengan memanfaatkan pendekatan *Natural Language Processing* (NLP).

Hasil dari proses *product matching* ini tidak hanya digunakan dalam pengembangan sistem *Price Optimization*, tetapi juga dipakai dalam penyelarasan data produk di portal internal perusahaan (*database* perusahaan) untuk meningkatkan konsistensi dan kualitas data produk. Di samping itu, mahasiswa juga wajib melakukan *data preprocessing*, *feature engineering*, pembangunan model *demand forecasting* dengan algoritma *Random Forest Regression*, pengembangan sistem optimasi harga berdasarkan estimasi permintaan, serta penyusunan dashboard analitik melalui Looker Studio. Untuk mendukung penerapan sistem secara menyeluruh, mahasiswa juga mengembangkan antarmuka aplikasi web dengan menggunakan HTML, CSS, dan JavaScript, serta membangun layanan *backend* melalui FastAPI yang berfungsi sebagai jembatan antara model analitik dan antarmuka pengguna.

Oleh karena itu, peran mahasiswa dalam kegiatan Studi Independen tidak hanya sebatas analisis data, tetapi juga sebagai pengembang solusi analitik yang terintegrasi, mencakup pengumpulan data, penyelarasan data, analisis prediktif, optimasi keputusan, visualisasi bisnis, dan implementasi sistem pendukung keputusan (*Decision Support System*) yang dapat dimanfaatkan langsung oleh manajemen dan pengguna bisnis di CV DB Klik.

3.2 Metodologi Penyelesaian Tugas

Metode penyelesaian tugas dalam proyek *Price Optimization* di CV DB Klik dilaksanakan dengan pendekatan analitik *end-to-end*, yang mencakup tahap pengumpulan data, penyesuaian produk, pengembangan fitur, peramalan permintaan, optimasi harga, hingga penerapan sistem berbasis web. Metodologi ini dikembangkan untuk menciptakan sistem pendukung keputusan (*Decision Support System*) yang dapat membantu perusahaan dalam menetapkan strategi harga yang lebih kompetitif dan berdasarkan data.



Gambar 3.1 Flowchart Penyelesaian Proyek

3.2.1 Pengumpulan Data (*Data Collecting*)

Tahap pengumpulan dan integrasi data dilakukan dengan tujuan untuk memperoleh dataset yang komprehensif sebagai dasar dalam pengembangan sistem *Price Optimization*. Data yang digunakan berasal dari berbagai sumber, meliputi data produk internal CV DB Klik, data harga pokok penjualan (HPP), data penjualan historis yang diperoleh dari *sell center*, serta data produk dan harga kompetitor yang diperoleh melalui proses *web scraping*. Pada tahap ini, dilakukan proses ekstraksi, standarisasi format, pembersihan data, dan penggabungan (*merge*) antar sumber data sehingga diperoleh dataset terpadu yang memiliki struktur dan format yang seragam. Proses integrasi data ini mengacu pada konsep *data warehousing* dan *data integration*, di mana kualitas data menjadi faktor penting dalam keberhasilan proses analitik selanjutnya (Kimball & Ross, 2013). Output dari tahap ini adalah dataset terintegrasi yang terdiri atas informasi produk, histori penjualan, harga kompetitor, dan informasi profitabilitas perusahaan.

3.2.2 Pre-Processing

Tahap *pre-processing* merupakan proses awal yang bertujuan untuk meningkatkan kualitas data sebelum dilakukan proses *product matching*. Data yang digunakan pada penelitian ini berasal dari dua sumber, yaitu data produk internal CV DB Klik dan data produk kompetitor hasil *scraping* marketplace Shopee. Kedua sumber data memiliki karakteristik penulisan nama produk yang berbeda-beda, seperti penggunaan huruf kapital, simbol, tanda baca, singkatan, maupun variasi penulisan merek. Apabila kondisi tersebut tidak dinormalisasi terlebih dahulu, maka proses pengukuran kemiripan teks dapat menghasilkan nilai yang kurang akurat karena perbedaan format penulisan akan dianggap sebagai kata yang berbeda (Manning, Raghavan & Schütze, 2008).

Oleh karena itu, pada penelitian ini dilakukan beberapa tahapan *pre-processing* yang meliputi normalisasi nama produk, ekstraksi *brand*, penyaringan data berdasarkan *brand*, serta pembentukan atribut *clean product name*. Tahapan tersebut bertujuan menghasilkan representasi data yang lebih seragam sehingga dapat meningkatkan efektivitas proses pencocokan produk menggunakan metode TF-IDF dan *cosine similarity* pada tahap berikutnya (Salton & Buckley, 1988).

3.2.3 Product Matching

Tahap *product matching* merupakan salah satu implementasi *Natural Language Processing* (NLP) yang bertujuan untuk menyelaraskan produk internal perusahaan dengan produk kompetitor yang memiliki perbedaan penulisan nama produk, format SKU, maupun variasi penyebutan merek. Permasalahan ini termasuk ke dalam kategori *text similarity problem*, yaitu proses mengidentifikasi tingkat kemiripan antar dokumen atau teks tidak terstruktur (Manning et al., 2008). Input yang digunakan pada tahap ini adalah dataset produk internal CV DB Klik dan dataset produk kompetitor hasil *web scraping*.

Proses *product matching* diawali dengan tahapan *text preprocessing* yang meliputi normalisasi huruf menjadi huruf kapital (*uppercase normalization*), penghapusan karakter khusus, penghapusan spesifikasi produk yang tidak relevan, serta standarisasi nama produk. Selain itu, dilakukan pula proses penyelarasan nama merek menggunakan *kamusbrand.xlsx*, yaitu kamus khusus yang berisi daftar variasi penulisan merek elektronik dan gadget yang sering ditemukan pada marketplace. Penggunaan kamus domain-spesifik ini bertujuan untuk meningkatkan konsistensi representasi nama merek sehingga dapat meningkatkan akurasi pencocokan produk (Aggarwal, 2018). Setelah proses *preprocessing* selesai dilakukan, tahapan NLP dilanjutkan melalui proses ekstraksi fitur teks menggunakan metode:

3.2.2.1 Term Frequency-Inverse Document Frequency (TF-IDF)

Term Frequency-Inverse Document Frequency (TF-IDF) merupakan metode representasi teks yang digunakan untuk mengubah data tekstual menjadi representasi numerik berdasarkan tingkat kepentingan suatu kata pada sebuah dokumen relatif terhadap keseluruhan kumpulan dokumen (Manning et al., 2008). Pada penelitian ini, TF-IDF digunakan untuk menghitung bobot setiap kata pada nama produk sehingga kata-kata yang bersifat unik dan informatif memiliki pengaruh yang lebih besar dibandingkan kata-kata yang sering muncul. Hasil dari proses ini berupa matriks vektor numerik yang merepresentasikan karakteristik setiap produk dan digunakan sebagai dasar dalam proses perhitungan kemiripan.

3.2.2.2 Pembentukan konteks kata menggunakan *N-Gram*

N-Gram merupakan teknik NLP yang digunakan untuk membentuk sekumpulan kata atau karakter yang berurutan guna mempertahankan konteks dan struktur penulisan suatu teks (Jurafsky & Martin, 2023). Pada penelitian ini, pendekatan *N-Gram* digunakan untuk mengatasi variasi penulisan nama produk elektronik yang sering kali memiliki urutan kata berbeda namun merujuk pada produk yang sama. Dengan menggunakan kombinasi unigram dan bigram, model dapat menangkap hubungan antar kata secara lebih baik sehingga meningkatkan akurasi proses *product matching*.

3.2.2.3 Perhitungan tingkat kemiripan menggunakan *Cosine Similarity*

Cosine Similarity merupakan metode pengukuran kemiripan yang menghitung sudut antara dua vektor dalam ruang multidimensi (Manning et al., 2008). Pada penelitian ini, metode *Cosine Similarity* digunakan untuk menghitung tingkat kemiripan antara vektor TF-IDF dari produk internal dan produk kompetitor. Nilai kemiripan berada pada rentang 0 hingga 1, di mana nilai yang mendekati 1 menunjukkan tingkat kesamaan produk yang semakin tinggi. Produk dengan nilai *similarity score* tertinggi kemudian dipilih sebagai pasangan produk yang paling relevan.

Kombinasi ketiga metode tersebut dipilih karena terbukti efektif dalam menangani permasalahan pencocokan data teks tidak terstruktur pada platform e-commerce (Manning et al., 2008; Aggarwal, 2018).

3.2.4 Domain-Driven Feature Engineering

Tahap *domain-driven feature engineering* bertujuan untuk membentuk variabel baru yang mampu merepresentasikan pola historis penjualan, dinamika pasar, dan kondisi profitabilitas bisnis. Input pada tahap ini adalah dataset hasil integrasi dan *product matching*. Proses pembentukan fitur dilakukan berdasarkan pengetahuan domain retail dan strategi penetapan harga, sehingga dihasilkan fitur-fitur yang lebih representatif dibandingkan penggunaan data mentah secara langsung (Phillips, 2005). Feature engineering pada penelitian ini dibagi menjadi tiga kategori utama, yaitu:

3.2.3.1 Temporal features

- Lag Features, dibangun dengan menggeser data penjualan historis pada periode sebelumnya, misalnya $t-1$, $t-2$, dan $t-4$ minggu, untuk menangkap pola ketergantungan temporal.
- Rolling Mean, dihitung menggunakan rata-rata penjualan dalam jendela waktu tertentu, misalnya 4 minggu terakhir, untuk mengurangi fluktuasi data.
- Price Change, digunakan untuk mengukur perubahan harga dari periode sebelumnya dan mengidentifikasi sensitivitas konsumen terhadap perubahan harga.

3.2.3.2 Competitive features

- Price Gap, fitur ini digunakan untuk mengukur tingkat kompetivitas harga
- Price Rasio, fitur ini digunakan untuk mengetahui posisi harga relatif terhadap pasar.

3.2.3.3 Business/financial features

- Margin Feature, fitur ini digunakan untuk menjaga agar rekomendasi harga tetap berada pada batas profitabilitas perusahaan (tidak boleh kurang dari 3%)

Output dari tahap ini adalah dataset hasil rekayasa fitur yang siap digunakan pada proses pembangunan model prediksi.

3.2.5 Agregasi Data

Tahap selanjutnya setelah proses integrasi data adalah *data aggregation*, yaitu proses mengelompokkan data berdasarkan periode waktu, nama produk, dan merek untuk menghasilkan representasi data yang lebih ringkas dan siap digunakan pada tahap *feature engineering*. Agregasi dilakukan karena satu produk dapat memiliki beberapa data hasil pencocokan dengan berbagai kompetitor pada periode yang sama. Apabila data tersebut langsung digunakan untuk membangun model, maka akan terjadi duplikasi informasi dan ketidakseimbangan bobot data (*data redundancy and bias*) yang dapat memengaruhi proses pembelajaran model secara signifikan, sehingga menurunkan akurasi prediksi (Kaur dkk., 2018).

Pada penelitian ini, proses agregasi dilakukan menggunakan fungsi `groupby()` pada Python berdasarkan atribut `Datetime_DB`, `Nama_DB`, dan `Brand_DB`. Selanjutnya dilakukan proses agregasi terhadap beberapa atribut menggunakan fungsi statistik yang berbeda sesuai karakteristik datanya. Data internal seperti harga produk (`Harga_DB`) dihitung menggunakan nilai rata-rata (*mean*), sedangkan jumlah penjualan (`Qty_DB`) dan omset (`Omset_DB`) dihitung menggunakan nilai total (*sum*) karena merepresentasikan akumulasi transaksi pada periode tersebut.

Untuk data kompetitor, dilakukan agregasi menggunakan nilai minimum, rata-rata, dan maksimum pada atribut harga kompetitor (`Min_Harga_Komp`, `Avg_Harga_Komp`, dan `Max_Harga_Komp`). Selain itu dihitung pula rata-rata jumlah penjualan kompetitor (`Avg_Qty_Komp`), jumlah penjualan maksimum (`Max_Qty_Komp`), rata-rata nilai kemiripan hasil pencocokan produk (`Avg_Similarity`), serta jumlah kompetitor unik (`Jumlah_Kompetitor`) menggunakan fungsi `nunique()`.

3.2.6 Bangun Model untuk Demand Forecasting (Random Forest Regression)

Tahap prediksi permintaan bertujuan untuk memprediksi jumlah permintaan produk pada periode mendatang berdasarkan pola historis penjualan, kondisi pasar, dan karakteristik produk. Input yang digunakan adalah dataset hasil *feature engineering*. Pada tahap ini, digunakan algoritma *Random Forest Regression*, yaitu metode *ensemble learning* berbasis *decision tree* yang mampu menangani hubungan non-linear dan interaksi antar variabel yang kompleks (Breiman, 2001). Proses dilakukan melalui pembagian data pelatihan dan pengujian, pelatihan model, evaluasi performa model, serta pembuatan prediksi permintaan. Output dari tahap ini adalah model prediksi permintaan dan estimasi volume penjualan yang akan digunakan sebagai dasar dalam proses optimasi harga.

3.2.7 Operasi Optimasi Harga (Price Optimization)

Tahap optimasi harga bertujuan untuk menentukan rekomendasi harga optimal yang mampu meningkatkan profitabilitas perusahaan sekaligus mempertahankan daya saing pasar. Input yang digunakan adalah hasil prediksi permintaan, data Harga Pokok Penjualan (HPP), serta informasi harga kompetitor. Proses optimasi dilakukan dengan mensimulasikan berbagai skenario harga dan menghitung estimasi profit yang dapat diperoleh pada setiap skenario tersebut. Pendekatan ini termasuk

dalam kategori *prescriptive analytics*, yaitu proses menghasilkan rekomendasi keputusan berdasarkan hasil prediksi dan model bisnis yang telah dibangun sebelumnya (Liu & Sustik, 2021). Output dari tahap ini adalah rekomendasi harga optimal (*optimal price*) beserta estimasi profit dan volume penjualan yang dihasilkan.

3.2.8 Visualisasi dan Implementasi Sistem

Tahap visualisasi dan implementasi sistem bertujuan untuk mengubah hasil analisis menjadi sistem pendukung keputusan yang dapat digunakan secara langsung oleh pengguna bisnis. Input yang digunakan adalah hasil prediksi permintaan, hasil optimasi harga, dan indikator performa bisnis lainnya. Proses implementasi dilakukan dengan membangun dashboard analitik menggunakan Looker Studio, visualisasi interaktif menggunakan Chart.js, antarmuka web menggunakan HTML, CSS, dan JavaScript, serta integrasi model menggunakan FastAPI sebagai *backend service*. Selanjutnya, sistem dilakukan proses *deployment* menggunakan platform Netlify agar dapat diakses secara daring. Output dari tahap ini adalah sistem *Price Optimization* berbasis web yang mampu mendukung proses pengambilan keputusan bisnis secara real-time.

3.3 Pembelajaran Hal Baru

Selama pelaksanaan Studi Independen di CV DB Klik, penulis memperoleh pengalaman dalam mengembangkan sistem analitik secara end-to-end, mulai dari pengumpulan data, integrasi data, *product matching*, *feature engineering*, pembangunan model *machine learning*, hingga implementasi sistem berbasis web. Pengalaman ini memberikan pemahaman bahwa pembangunan sistem analitik di industri tidak hanya berfokus pada pembuatan model, tetapi juga pada kualitas data, proses bisnis, dan kebutuhan pengguna.

Pada tahap pengumpulan dan integrasi data, penulis mempelajari bagaimana mengolah data yang berasal dari berbagai sumber, seperti data internal perusahaan, data penjualan historis, data Harga Pokok Penjualan (HPP), serta data kompetitor hasil *web scraping*. Proses ini memberikan pemahaman mengenai pentingnya kualitas data dan konsistensi format sebelum dilakukan analisis lebih lanjut.

Penulis juga memperoleh pengalaman dalam menerapkan *Natural Language Processing* (NLP) untuk melakukan *product matching* antara produk internal perusahaan dan produk kompetitor menggunakan kombinasi metode TF-IDF, N-Gram, dan Cosine Similarity. Melalui proses ini, penulis memahami bahwa keberhasilan analisis sangat dipengaruhi oleh kualitas proses *preprocessing*, standarisasi merek, serta pemilihan metode representasi teks yang tepat. Selain itu, penulis mempelajari proses *feature engineering* berbasis domain bisnis untuk membangun fitur-fitur seperti *Price Gap*, *Price Ratio*, *Margin Feature*, *Lag Feature*, *Rolling Mean*, dan *Price Change*. Proses ini memberikan pemahaman bahwa pengetahuan terhadap domain bisnis memiliki peran penting dalam meningkatkan performa model prediksi.

Pada tahap pemodelan, penulis memperoleh pengalaman dalam membangun model *Random Forest Regression* untuk memprediksi permintaan produk. Selama proses pengembangan, dilakukan beberapa kali evaluasi dan *retraining* model untuk menghasilkan prediksi yang lebih sesuai dengan kondisi bisnis perusahaan. Selain itu, penulis juga mempelajari proses optimasi harga berbasis simulasi skenario (*scenario-based optimization*) untuk menghasilkan rekomendasi harga yang optimal.

Penulis juga memperoleh pengalaman dalam mengintegrasikan model *machine learning* ke dalam aplikasi berbasis web menggunakan FastAPI sebagai *backend*, HTML, CSS, dan JavaScript sebagai *frontend*, serta membangun dashboard visual menggunakan Looker Studio. Pengalaman ini memberikan pemahaman mengenai bagaimana hasil analisis data dapat diimplementasikan menjadi sistem pendukung keputusan yang dapat digunakan secara langsung oleh pengguna bisnis.

BAB IV


HASIL DAN PEMBAHASAN

4.1 Hasil

Pelaksanaan proyek pengembangan sistem *Price Optimization berbasis Machine Learning* pada CV DB Klik berhasil menghasilkan sebuah sistem pendukung keputusan (*Decision Support System*) yang mengintegrasikan proses pengumpulan data, pencocokan produk (*product matching*), prediksi permintaan (*demand forecasting*), optimasi harga, visualisasi data, serta implementasi sistem berbasis web. Seluruh tahapan yang direncanakan pada awal proyek berhasil diimplementasikan dan menghasilkan beberapa luaran utama yang dapat digunakan secara langsung oleh perusahaan. Secara umum, hasil yang diperoleh dari proyek ini meliputi:

1. Model *Random Forest Regression* untuk prediksi permintaan.
2. Sistem simulasi optimasi harga berbasis prediksi permintaan.
3. Dashboard visualisasi bisnis menggunakan Looker Studio.
4. Website simulasi harga berbasis FastAPI, HTML, CSS, dan JavaScript.

4.1.1 Dataset hasil integrasi produk internal dan kompetitor.



Gambar 4.1 Ringkasan Integrasi dataset internal dan Kompetitor


Proses dimulai dengan menggabungkan seluruh file penjualan mingguan/bulanan dari folder data (format .xlsx) milik CV DB Klik dan belasan kompetitor menjadi satu dataset gabungan berjumlah 106.814 baris data transaksi produk. Setelah proses pembersihan data (menghapus baris dengan nama produk, harga, atau kuantitas kosong, serta normalisasi format harga dari "Rp" dan pemisah ribuan menjadi numerik), dataset bersih tersisa 106.759 baris. Dari hasil pemisahan berdasarkan kolom "Perusahaan", diperoleh 8.095 baris transaksi milik DB Klik dengan 4.355 produk unik, sementara sisanya berasal dari 20-an kompetitor seperti Enter Komputer, Blessing Computer, Starcomp, dan lainnya. Selain pembersihan harga dan kuantitas, dilakukan juga ekstraksi brand menggunakan kamus alias brand, normalisasi nama produk (clean_name), serta penanganan 6.517 data dengan brand

"UNKNOWN" yang diperbaiki menggunakan analisis frekuensi kata. Dataset terintegrasi inilah yang menjadi fondasi seluruh tahap selanjutnya, mulai dari pencocokan produk hingga pemodelan prediksi permintaan.

Tabel 4.1 Ringkasan Dataset Hasil Integrasi


Sumber Data	Keterangan
Database Produk	Data SKU dan informasi produk
Data Penjualan	Riwayat penjualan mingguan
Data HPP	Harga Pokok Penjualan
Data Kompetitor	Harga dan penjualan kompetitor
Hasil Integrasi	Dataset analisis optimasi harga

4.1.2 Sistem product matching berbasis Natural Language Processing



Gambar 4.2 Coverage Hasil Product Matching


Sistem pencocokan produk dirancang dua tahap. Tahap pertama adalah pencocokan berbasis kode/model utama produk (*rule-based matching*), yaitu mengekstraksi kode model dominan dari nama produk menggunakan *regular expression*, kemudian mencocokkan produk DB Klik dengan produk kompetitor yang memiliki *brand* dan model yang sama. Tahap ini berhasil menemukan 1.349 produk yang cocok (*coverage* 30,98%



Gambar 4.3 *Distribusi similarity score*

Tahap kedua menerapkan pendekatan NLP berbasis TF-IDF dan N-gram (1–2 kata) yang diikuti perhitungan *cosine similarity* terhadap sisa produk yang belum cocok pada tahap pertama, dengan ambang batas *similarity* di atas 0,6. Pendekatan ini menambahkan 318 produk baru yang berhasil dicocokkan, dengan rata-rata *similarity* 0,71 (rentang 0,60–1,00).


Penggabungan kedua metode menghasilkan total 1.667 produk DB Klik yang berhasil dipetakan ke produk kompetitor sejenis, atau *coverage* akhir sebesar 38,28% dari total produk unik DB Klik. Pendekatan kombinasi *rule-based* dan TF-IDF *cosine similarity* ini sejalan dengan penelitian yang menunjukkan bahwa metode *cosine similarity* dengan pembobotan TF-IDF dapat meningkatkan akurasi pencocokan kode produk dibandingkan pencarian berbasis kata kunci sederhana (Defit & Widi Nurcahy, 2021).




Gambar 4.4 Perbandingan harga hasil *product matching*

Berdasarkan Gambar 4.4, terlihat bahwa sebagian besar hasil *product matching* menghasilkan pasangan produk dengan rentang harga yang relatif serupa antara produk internal CV DB Klik dan produk kompetitor. Hal ini ditunjukkan oleh sebaran titik yang cenderung membentuk hubungan positif antara harga DB Klik dan harga kompetitor.

Meskipun terdapat beberapa *outlier* pada rentang harga yang sangat tinggi, secara umum hasil visualisasi menunjukkan bahwa proses *product matching* berhasil menghasilkan pasangan produk yang cukup representatif dan dapat digunakan pada tahap analisis serta pemodelan selanjutnya.



Gambar 4.5 Top 10 Brand dengan Match Terbanyak




Gambar 4.6 Perbandingan harga hasil *product matching*

Berdasarkan Gambar 4.5 dan Gambar 4.6, hasil *product matching* menunjukkan bahwa brand LOGITECH memiliki jumlah pasangan produk terbanyak dibandingkan brand lainnya, dengan jumlah *match* mencapai lebih dari 12.000 pasangan, diikuti oleh TP-LINK, LG, GREE, dan ASUS. Hal ini menunjukkan bahwa produk-produk dari brand tersebut memiliki ketersediaan dan tingkat kesesuaian yang tinggi antara data internal CV DB Klik dan data kompetitor. Sementara itu, berdasarkan distribusi jumlah *match* per kompetitor, perusahaan ENTER KOMPUTER menghasilkan jumlah pasangan produk terbanyak, diikuti oleh BLESSING COMPUTER, UGREEN, dan beberapa kompetitor lainnya. Hasil ini mengindikasikan bahwa proses *product matching* berhasil mengidentifikasi kesamaan produk secara efektif pada berbagai brand dan kompetitor, sehingga menghasilkan cakupan data pasar yang cukup luas dan representatif untuk digunakan pada tahap *feature engineering*, prediksi permintaan, dan optimasi harga selanjutnya.

4.1.3 Model Random Forest Regression untuk prediksi permintaan

Setelah data hasil matching diagregasi menjadi fitur per produk per periode waktu (harga, harga kompetitor, gap harga, lag harga, rolling average, fitur waktu, dan lain-lain), dibangun model Random Forest Regression untuk memprediksi kuantitas penjualan (dalam bentuk log-transform, Log_Qty_DB) dengan 100 pohon ($n_estimators=100$) dan kedalaman maksimum 10. Dari total 1.527 baris data fitur, dataset dibagi menjadi data latih (1.221 baris) dan data uji (306 baris) dengan rasio 80:20. Model versi pertama (menyertakan fitur rolling kuantitas) menghasilkan performa MAE sebesar 104,09 unit, RMSE sebesar 355,55, dan R^2 sebesar 0,9625 pada data uji, dengan R^2 pada data latih sebesar 0,9861, menunjukkan


model mampu menjelaskan lebih dari 96% variasi permintaan aktual. Pada analisis feature importance, fitur *Rolling_Qty_3* (rata-rata kuantitas penjualan 3 periode terakhir) mendominasi kontribusi prediksi (94,8%), sehingga dilakukan eksperimen model kedua tanpa fitur tersebut. Model versi kedua menghasilkan performa yang lebih rendah (MAE 168,36, RMSE 494,28, R^2 0,8520), dengan fitur *Jumlah_Kompetitor* (37,7%) dan *Max_Qty_Komp* (14,9%) menjadi fitur paling berpengaruh. Hasil ini mengindikasikan bahwa pola historis penjualan jangka pendek serta intensitas persaingan harga merupakan faktor utama penentu permintaan produk di DB Klik. Penggunaan Random Forest Regression untuk prediksi permintaan/penjualan retail ini konsisten dengan studi yang menerapkan algoritma random forest regression untuk memprediksi pendapatan penjualan ritel (Ganguly dan Mukherjee, 2024).



Gambar 4.7 Perbandingan error model

Berdasarkan Gambar 4.7, Model v1 menghasilkan nilai MAE dan RMSE yang lebih rendah dibandingkan Model v2, yang menunjukkan bahwa secara numerik Model v1 memiliki tingkat kesalahan prediksi yang lebih kecil. Namun demikian, pada penelitian ini Model v2 tetap dipilih sebagai model akhir karena menggunakan proses *feature engineering* yang lebih lengkap, seperti penambahan fitur *Price Gap*, *Price Ratio*, *Margin*, *Lag Feature*, *Rolling Average*, serta fitur kalender yang mampu merepresentasikan kondisi bisnis secara lebih baik. Selain itu, Model v2 menghasilkan pola prediksi yang lebih realistis ketika digunakan pada proses simulasi perubahan harga dan optimasi harga, sehingga lebih sesuai dengan tujuan utama penelitian, yaitu mendukung pengambilan keputusan penentuan harga produk. Peningkatan nilai MAE dan RMSE pada Model v2 masih berada pada batas yang dapat diterima, sehingga dipandang sebagai *trade-off* yang wajar untuk memperoleh model yang lebih representatif terhadap kondisi nyata dan lebih mampu diimplementasikan pada sistem optimasi harga.


4.1.4 Sistem simulasi optimasi harga berbasis prediksi permintaan



Gambar 4.8 Perbandingan error model v1 dan v2

Model v1 menunjukkan performa yang lebih baik dibandingkan Model v2 berdasarkan seluruh metrik evaluasi. Model v1 memperoleh nilai MAE sebesar sekitar 103 dan RMSE sebesar sekitar 355, lebih rendah dibandingkan Model v2 yang memiliki MAE sekitar 168 dan RMSE sekitar 493. Selain itu, nilai koefisien determinasi (R^2) Model v1 mencapai 0,9625, sedangkan Model v2 sebesar 0,8520, yang menunjukkan bahwa Model v1 memiliki kemampuan yang lebih baik dalam menjelaskan variasi data target. Meskipun demikian, pada implementasi sistem optimasi harga penelitian ini digunakan Model v2 karena model tersebut tidak bergantung pada fitur *Rolling_Qty*, sehingga lebih mudah diimplementasikan pada aplikasi yang digunakan oleh CV DB Klik. Dalam praktiknya, data penjualan historis atau nilai *rolling* tidak selalu tersedia atau diperbarui secara konsisten untuk setiap produk, sehingga penggunaan Model v2 dinilai lebih praktis, fleksibel, dan lebih sesuai untuk kebutuhan simulasi harga secara real-time. Oleh karena itu, penelitian ini mempertimbangkan aspek implementasi sistem selain performa statistik model, sehingga dipilih model yang lebih mudah diterapkan pada lingkungan operasional meskipun memiliki tingkat kesalahan prediksi yang sedikit lebih tinggi..

4.1.5 Dashboard visualisasi bisnis menggunakan Looker Studio



Gambar 4.9 Tampilan *dashboard* looker studio


Dashboard Looker Studio yang dibangun berfokus pada pemantauan kinerja penjualan toko di marketplace (Shopee) secara berkala, bukan merupakan kelanjutan langsung dari output notebook product matching/demand forecasting. Dashboard ini menyajikan ringkasan metrik utama untuk periode bulan berjalan dibandingkan bulan sebelumnya (contoh: Mei 2026 vs April 2026), meliputi total omset, total pelanggan (customer), dan total produk terjual, masing-masing dilengkapi dengan persentase perubahan (growth) terhadap bulan sebelumnya.

Selain itu, dashboard juga menampilkan biaya iklan (biaya iklan bulan berjalan vs bulan sebelumnya) beserta nilai ACOS (Advertising Cost of Sales) sebagai indikator efisiensi belanja iklan terhadap omset yang dihasilkan. Pada bagian visual, disajikan grafik batang perbandingan omset per kategori produk antara dua periode, yang menunjukkan kategori dengan kontribusi penjualan terbesar seperti Monitor serta Desktop & Laptop Components. Di bagian bawah dashboard, terdapat tabel analisis per kategori dan analisis per produk yang merinci omset, growth rate value (Rp dan %), serta growth rate kuantitas (unit dan %) untuk setiap kategori dan produk individual, sehingga memudahkan tim manajemen

mengidentifikasi produk atau kategori yang mengalami penurunan maupun peningkatan penjualan secara cepat.

Dengan demikian, dashboard ini berfungsi sebagai alat pemantauan performa penjualan dan efisiensi iklan secara menyeluruh, melengkapi hasil analisis product matching dan prediksi permintaan yang telah dilakukan pada tahap notebook. Penggunaan Looker Studio sebagai alat visualisasi data bisnis ini sejalan dengan praktik yang memanfaatkan Google Looker Studio untuk menampilkan data dalam bentuk tabel, grafik, dan visual interaktif agar informasi lebih mudah dipahami oleh pengguna (Sulaimain, et al 2024).

4.1.6 Website simulasi harga berbasis FastAPI, HTML, CSS, dan JavaScript



Gambar 4.10 Tampilan Dashboard Looker

Model Random Forest yang telah dilatih dan disimpan dalam format .pkl (rf_demand_model.pkl dan rf_demand_model_v2.pkl) menggunakan joblib, kemudian diintegrasikan ke dalam sebuah aplikasi web menggunakan framework FastAPI sebagai backend untuk melayani permintaan prediksi (serving model), sementara HTML, CSS, dan JavaScript digunakan untuk membangun antarmuka pengguna pada sisi frontend. Melalui website ini, pengguna (misalnya tim manajemen atau bagian penjualan) dapat memasukkan parameter harga suatu produk dan memperoleh estimasi permintaan serta simulasi profit secara langsung, tanpa perlu menjalankan kode Python secara manual. Pendekatan deployment model machine learning ke aplikasi web menggunakan FastAPI ini sejalan dengan praktik umum yang mengintegrasikan model machine learning ke dalam aplikasi berbasis website melalui API yang dibangun menggunakan framework FastAPI (Jurnal Informatika Terpadu, 2024).


4.2 Pembahasan

4.2.1 Pengumpulan Data

4.2.1.1 Data Hasil Scraping

Data hasil scraping memiliki kolom variabel datetime, Nama Produk, Harga, Qty (jumlah terjualnya barang), Qty (mg),

Omset (mg). Terdapat 19 perusahaan yang discraping (salah satunya perusahaan DB Klik sendiri



Gambar 4.11 File Hasil Scraping

Pada data hasil *scraping* milik DB Klik terdapat 8284 Baris produk, dengan total produk yang unik adalah 2534 produk. Sedangkan, untuk data kompetitor secara keseluruhan ada 98.719 produk. Dengan rincian sebagai berikut:

Tabel 4.2 Total Produk di Setiap Perusahaan

Perusahaan	Total Produk
ENTER KOMPUTER	13.826
BLESSING COMPUTER	12.037
STARCOMP	9.635
SURYA MITRA ONLINE	7.827
JAYAPC	7.642
EXPERT KOMPUTER	7.375
MULTIFUNGSI	4.991
YOUNGS COMPUTER	4.862
GEGESTORE	4.545
ITSHOP	4.103
TECH ISLAND	3.674
NANO COMPUTER	3.456
PLANET COMPUTER	3.354
ONE IT	3.093
IMPC	3.026
ABDITAMA	2.688
LEVEL99	2.490
MOLONG	95

4.2.1.2 Data Sell Center Shopee

Data *sell center* Shopee di sini merupakan kumpulan data produk dari marketplace shopee yang ada pada akun DB Klik. Dari data *sell center* ini terdapat 41 kolom variabel yaitu Kode Produk, Nama Produk, Kode Variasi, Nama Variasi, SKU Induk, SKU, Harga, GTIN, Stok: SMI Medan, Stok: SMI Cibitung, Stok: DBKlik Malang, Stok: DBKlik Semarang, Stok: DBKlik Jakarta, Stok: SMI Surabaya, Stok: SMI Ancol, Stok: SMI WH Semarang, Stok: SMI Yogyakarta, Stok: SMI Bandung, Stok: DBKlik Bali, Stok: DBKlik Yogya, Stok: DBKlik Lebaksar, Stok: DB Klik ITC, Stok: DB JKT NEW, Stok: DB Bali New, Stok: DB Malang NEW, Stok: DB YGY NEW, Stok: DB SMG NEW, Stok: DB LS NEW, Stok: GOLDEN SOUND, Stok: DB Klik-Golden, Stok: DB JKT NEW 2, Stok: DB SMG NEW 2, Stok: DB Malang NEW 2, Stok: DB YGY NEW 2, Stok: DB Klik - ACK, Stok: DBKlik Surabaya, Min. Jumlah Pembelian, Maks. Jumlah Pembelian, Maks. Jumlah Pembelian - Tanggal Mulai, Maks. Jumlah Pembelian - Jumlah Hari, Maks. Jumlah Pembelian - Tanggal Berakhir.

Dari keseluruhan data tersebut, diperlukan variabel Nama Produk, SKU Induk dan SKU (variasi) guna menyatukan variabel HPP dari data portal DB Klik dengan data DB Klik hasil *scraping*. Pada proses pencocokan Nama Produk antar hasil data *scraping* dengan data *sell center*, dilakukan beberapa tahapan pre-processing text diantaranya konversi tipe data menjadi string, *case folding* (mengubah menjadi huruf kapital), menghapus karakter selain huruf dan angka, normalisasi, dan trimming khusus untuk kolom variabel 'Nama Produk' di kedua data. Kemudian digabungkan dengan 'merge' sesuai dengan 'Nama Produk' yang sama. 'merge' dilakukan dua kali karena ada dua data *sell cente*, kemudian keduanya digabungkan menjadi satu file excel.

Datetime	Nama Produk	Harga	Qty	Omset (bln)	Qty (mg)	Omset (mg)	clean_name	SKU FINAL
#####	Monitor Gamii	1590000	101	160590000	25	39750000	MONITOR GAMMOMI0001-B009	
#####	Xiaomi Smart /	1060000	106	112360000	26	27560000	XIAOMI SMART AMI014	
#####	LG 24U411A LE	1220000	88	107360000	22	26840000	LG 24U411A LE LML066-B009	
#####	ASUS ExpertCe	15499000	6	92994000	1	15499000	ASUS EXPERTCE PCAIOAS0008-W-B009	
#####	Monitor Gamii	2550000	34	86700000	8	20400000	MONITOR GAMLMSKY0002-B012	
#####	ASUS PC AIO E	11199000	7	78393000	1	11199000	ASUS PC AIO E3 HCPUAS305-B009	
#####	MSI PRO LED N	1315000	59	77585000	14	18410000	MSI PRO LED M HMOMS58-B009	
#####	XIAOMI G27i 1	1950000	39	76050000	9	17550000	XIAOMI G27i 1E HMOMI007-B012	
#####	Xiaomi Smart /	1620000	44	71280000	11	17820000	XIAOMI SMART AMI013	
#####	QWERTY LED N	560000	113	63280000	28	15680000	QWERTY LED MHMOQWR0001-B008	
#####	Monitor Gamii	2125000	26	55250000	6	12750000	MONITOR GAMLMSKY0001-B009	
#####	MSI LED Monit	1390000	39	54210000	9	12510000	MSI LED MONITHMOMS46-B009	
#####	Monitor VIEW:	995000	50	49750000	12	11940000	MONITOR VIEW MOV50005-B008	
#####	LEXAR Flashdis	91000	494	44954000	123	11193000	LEXAR FLASHDI: HFDL0009-GY	
#####	Monitor MSI P	1180000	36	42480000	9	10620000	MONITOR MSI IHMOMS31.P-W-B009	
#####	MSI LED Monit	1605000	25	40125000	6	9630000	MSI LED MONITHMOMS63-B009	
#####	Lexar Flashdisl	74000	534	39516000	133	9842000	LEXAR FLASHDI: HFDL0007	
#####	LG 22U401A LE	1195000	33	39435000	8	9560000	LG 22U401A LE LML064-B008	
#####	MSI PRO LED N	1095000	35	38325000	8	8760000	MSI PRO LED M HMOMS54-B008	
#####	Monitor Gamii	1409000	27	38043000	6	8454000	MONITOR GAMHMOLV69.P-B009	

Gambar 4.12 Contoh Data hasil merge Scrapping dan SKU
4.2.1.3 Export Data Portal (DB Klik)

Pada tahapan *export data portal*, penulis memperoleh data produk internal CV DB Klik yang berasal dari Portal DB Klik. Data yang diekspor terdiri atas beberapa variabel penting, yaitu SKU, Kategori, Brand, Nama

Accurate, Stock Total, HPP (Latest), Shopee, Kategori Shopee, Margin Harga Shopee (Nilai), dan Margin Persen Shopee (%). Data tersebut kemudian digunakan sebagai sumber informasi utama mengenai identitas produk dan harga pokok penjualan (HPP).

Selanjutnya, dilakukan proses pencocokan (*matching*) antara data portal dan data *sell center* menggunakan variabel SKU sebagai *primary key*. Apabila nilai SKU pada kedua dataset sesuai, maka atribut-atribut dari data portal, khususnya informasi HPP (Latest), akan ditambahkan ke data penjualan historis sehingga setiap produk memiliki informasi harga jual, jumlah penjualan, serta harga pokok penjualan dalam satu dataset yang terintegrasi.

Pada proses ini ditemukan bahwa tidak seluruh produk memiliki informasi HPP (Latest) pada Portal DB Klik. Produk yang tidak memiliki nilai HPP tidak dapat digunakan pada proses pembangunan model optimasi harga karena perhitungan profit dan margin memerlukan informasi harga pokok sebagai dasar perhitungan. Oleh karena itu, data yang tidak memiliki HPP dipisahkan dari dataset utama dan tidak diikutsertakan pada proses pemodelan. Setelah proses integrasi dan penyaringan data dilakukan, jumlah produk yang semula sebanyak 8.284 produk berkurang menjadi sekitar 5.480 produk yang memiliki informasi HPP lengkap dan siap digunakan pada tahapan *product matching*, *feature engineering*, pembangunan model prediksi permintaan, serta optimasi harga.

Penyaringan data berdasarkan kelengkapan atribut merupakan salah satu tahapan penting dalam proses *data preprocessing* karena dapat meningkatkan kualitas data yang digunakan untuk membangun model prediksi serta mengurangi potensi kesalahan akibat nilai yang hilang (*missing values*) (Han, Kamber and Pei, 2012).

4.2.2 Pre-processing

4.2.2.1 Normalisasi Nama Produk

Pada tahap ini seluruh nama produk diubah menjadi huruf kapital (*case folding*), kemudian dilakukan penghapusan karakter khusus, tanda baca, simbol, serta spasi berlebih yang tidak memiliki makna terhadap identitas produk. Tidak hanya diberlakukan untuk nama produk, tetapi normalisasi ini juga diterapkan untuk harga supaya tidak ada format penulisan harga yang berbeda dan seluruh harga terdeteksi sebagai *numeric*.

```
import re

def clean_text(text):
    text = str(text).upper()
    text = re.sub(r'[\A-Z0-9 ]', ' ', text)
    text = re.sub(r'\s+', ' ', text)
    return text.strip()

df_all["clean_name"] = (
    df_all["Nama Produk"]
    .apply(clean_text)
)

df_all["Harga"] = (
    df_all["Harga"]
    .astype(str)
    .str.replace("Rp", "")
    .str.replace(".", "")
    .str.replace(",", "")
    .str.strip()
)
```

Gambar 4.13 *Code Pre-processing* Nama Produk dan Harga

Normalisasi teks merupakan salah satu tahapan penting dalam *text preprocessing* karena dapat mengurangi variasi penulisan yang sebenarnya mengacu pada entitas yang sama. Menurut Manning, Raghavan dan Schütze (2008), proses normalisasi bertujuan mengurangi kompleksitas representasi dokumen sehingga kata-kata yang memiliki makna sama tetapi berbeda format penulisannya dapat diperlakukan sebagai token yang identik. Dengan demikian, proses pembobotan kata pada tahap selanjutnya menjadi lebih konsisten. Selain itu, Singhal (2001) menjelaskan bahwa kualitas representasi dokumen sangat menentukan performa sistem *information retrieval*. Dokumen yang telah dinormalisasi akan menghasilkan representasi vektor yang lebih stabil sehingga meningkatkan akurasi dalam proses pencarian kemiripan antar dokumen.

Tabel 4.3 Contoh Perbedaan Sebelum dan Sesudah Normalisasi Nama Produk

Nama Produk	Clean name
FlashDisk Kingston DT70 128GB - DataTraveler 70 128 GB USB Type-C	FLASHDISK KINGSTON DT70 128GB DATATRAVELER 70 128 GB USB TYPE C
FlashDisk Lexar OTG Jumpdrive D400 128GB - Flash Disk 128 GB USB-C 3.1	FLASHDISK LEXAR OTG JUMPDRIVE D400 128GB FLASH DISK 128 GB USB C 3 1
VGA MSI GeForce RTX 4060 Ventus 2X Black OC 8GB - 8 GB DDR6	VGA MSI GEFORCE RTX 4060 VENTUS 2X BLACK OC 8GB 8 GB DDR6
Kingston SSD NV3 M.2 Pcie Gen4 Nvme 1TB - M2 1 TB	KINGSTON SSD NV3 M 2 PCIE GEN4 NVME 1TB M2 1 TB

4.2.2.2 Ekstraksi Brand

Setelah seluruh nama produk dinormalisasi, dilakukan proses ekstraksi *brand* menggunakan kamus merek (*brand dictionary*) yang telah disusun berdasarkan daftar merek resmi yang dimiliki CV DB Klik. Tahapan ini dilakukan untuk mengidentifikasi merek setiap produk meskipun terdapat variasi penulisan pada marketplace. Sebagai contoh, penulisan "TP Link", "TP-LINK", maupun "Tplink" akan dikenali sebagai satu merek yang sama, yaitu TP-LINK. Proses standarisasi tersebut bertujuan agar atribut *brand* menjadi konsisten pada seluruh dataset sehingga dapat digunakan sebagai salah satu atribut utama dalam proses pencocokan produk.

Menurut Manning, Raghavan dan Schütze (2008), proses standarisasi terhadap entitas yang memiliki banyak variasi penulisan merupakan bagian penting dalam *entity normalization* karena mampu mengurangi ambiguitas data. Dengan adanya atribut *brand* yang konsisten, kemungkinan terjadinya pencocokan

antarproduk dari merek yang berbeda dapat diminimalkan. Hasil ekstraksi menunjukkan bahwa sebagian besar produk berhasil diberikan label *brand*. Distribusi jumlah produk berdasarkan *brand* dapat dilihat pada

4.2.2.3 Penyaringan Data Berdasarkan Brand

Tahap berikutnya adalah melakukan penyaringan data berdasarkan kesamaan *brand*. Pada tahap ini hanya produk yang berasal dari merek yang sama yang akan dipertimbangkan pada proses pencocokan berikutnya. Strategi tersebut digunakan untuk memperkecil ruang pencarian (*search space*) sehingga proses pencocokan tidak membandingkan produk yang berasal dari merek berbeda. Pendekatan ini juga dapat mengurangi kemungkinan terjadinya *false matching*, yaitu kondisi ketika dua produk memiliki nama yang mirip tetapi berasal dari produsen yang berbeda.

Menurut Salton dan Buckley (1988), pembatasan ruang pencarian sebelum proses pembobotan dokumen dapat meningkatkan efisiensi sistem pencarian informasi karena jumlah kandidat yang dibandingkan menjadi lebih sedikit. Selain itu, Singhal (2001) menyatakan bahwa pengurangan kandidat yang tidak relevan mampu meningkatkan *precision* pada proses *information retrieval*.

Dalam pembentukan tahapan ini, ditemukan banyak sekali produk yang tidak terdeteksi brand karena variasi penulisan merek, penggunaan kata pemasaran, singkatan, maupun karakter tambahan pada nama produk.


```
unknown = df_all[
    df_all["Brand"] == "UNKNOWN"
]

print("Jumlah UNKNOWN :", len(unknown))

... Jumlah UNKNOWN : 6517
```

Gambar 4.14 Hasil checking brand yang tidak diketahui

Gambar 4.15 Stopwords dan kata yang karakter tambahan



Kondisi	Unknown
Sebelum preprocessing tambahan	6517
Setelah preprocessing tambahan	
DB Klik + Kompetitor	3456
DB Klik	24

Tabel 4.5 Perbedaan jumlah dataset setelah *brand applied*

41

4.2.3 Product Matching

4.2.3.1 Product Matching dengan Kode Model

Pada tahap pertama, proses *product matching* dilakukan menggunakan pendekatan *attribute-based matching* dengan memanfaatkan atribut identitas utama produk, yaitu *brand*, *main model*, dan *product specifications*. Pendekatan ini dipilih karena sebagian besar produk elektronik dan perangkat teknologi memiliki kode model (*model identifier*) yang bersifat unik dan konsisten, sehingga mampu merepresentasikan identitas produk secara lebih akurat dibandingkan hanya menggunakan nama produk (*product title*) yang cenderung memiliki variasi penulisan antar-platform (Li et al., 2020; Mudgal et al., 2021). Penggunaan atribut identitas utama juga bertujuan untuk meningkatkan presisi pencocokan serta mengurangi ambiguitas pada produk yang memiliki nama komersial serupa.

Berdasarkan hasil ekstraksi atribut pada tahap sebelumnya, setiap produk direpresentasikan ke dalam tiga komponen utama, yaitu *Brand*, *Main Model*, dan *Specifications*. Selanjutnya, proses pencocokan dilakukan secara bertahap (*hierarchical matching*) dengan menerapkan beberapa aturan. Pertama, produk internal DB Klik dan produk kompetitor harus memiliki atribut *brand* yang identik. Kedua, kedua produk harus memiliki *main model* yang sama sebagai representasi identitas utama produk. Ketiga, apabila produk memiliki atribut spesifikasi tambahan, seperti kapasitas penyimpanan, tipe memori, atau konfigurasi perangkat keras lainnya, maka atribut tersebut juga harus memiliki kesesuaian. Pendekatan berbasis aturan (*rule-based matching*) ini digunakan untuk mengurangi kemungkinan terjadinya *false matching* pada produk yang memiliki kemiripan nama tetapi berasal dari model atau konfigurasi produk yang berbeda (Ebraheem et al., 2020; Konda et al., 2022).

Tabel 4.6 Aturan yang harus ada antara DB Klik dan Kompetitor supaya bisa dicocokkan dengan kode model

Brand	Main Model	Specs	Hasil
TP-LINK	AX23	-	Match
ASUS	RTX5070	16GB	Match

Dengan demikian, penerapan *attribute-based matching* pada tahap awal berfungsi sebagai mekanisme penyaringan (*candidate filtering*) untuk menghasilkan pasangan produk dengan tingkat kesesuaian yang bisa dibilang cukup untuk ribuan produk. Tahapan ini berhasil menangkap 1349 produk, dengan total *coverage* data keseluruhan yaitu 30.98% sebelum dilakukan

proses pengukuran kemiripan berbasis *Natural Language Processing* pada tahapan berikutnya.

4.2.3.2 TF-IDF

Setelah proses *product matching* berbasis atribut identitas utama (*brand*, *main model*, dan *specifications*) dilakukan, masih terdapat sejumlah produk yang belum berhasil dipasangkan. Oleh karena itu, dilakukan pendekatan berbasis *Natural Language Processing* (NLP) menggunakan metode *Term Frequency-Inverse Document Frequency* (TF-IDF) untuk merepresentasikan nama produk ke dalam bentuk vektor numerik. Metode TF-IDF dipilih karena mampu memberikan bobot yang lebih besar pada kata-kata yang bersifat spesifik dan informatif, serta mengurangi pengaruh kata-kata yang terlalu umum pada seluruh korpus dokumen (Manning et al., 2008).

Pada penelitian ini, proses pembentukan representasi TF-IDF dilakukan menggunakan parameter *ngram_range=(1,2)* dan *min_df=2*. Parameter *ngram_range=(1,2)* digunakan untuk membentuk fitur berupa *unigram* dan *bigram*, sehingga model tidak hanya mempertimbangkan kata tunggal tetapi juga kombinasi dua kata yang berurutan. Pendekatan ini dipilih karena nama produk elektronik sering kali memiliki informasi penting yang tersusun dalam bentuk frasa, seperti "RTX 4060", "CORE I7", atau "DDR5 RAM". Sementara itu, parameter *min_df=2* digunakan untuk menghilangkan token yang hanya muncul satu kali pada seluruh korpus karena dianggap kurang representatif dan berpotensi meningkatkan *noise* pada proses pencocokan (Aggarwal, 2018).

Tabel 4.7 Parameter TF-IDF yang digunakan

Parameter	Nilai	Keterangan
<i>ngram_range</i>	(1,2)	Menggunakan unigram dan bigram
<i>min_df</i>	2	Menghilangkan token yang muncul satu kali
Corpus	Seluruh clean_name	Vocabulary dibangun dari seluruh produk
Analyzer	Word	Analisis berbasis kata

Proses pembentukan *vocabulary* dilakukan menggunakan seluruh data *clean_name* melalui proses *fitting* pada keseluruhan korpus produk. Pendekatan ini bertujuan untuk menghasilkan representasi fitur yang konsisten antara produk internal DB Klik dan produk kompetitor, sehingga setiap token yang muncul pada kedua sumber data dapat direpresentasikan dalam ruang vektor yang sama. Dengan demikian, proses perhitungan kemiripan pada tahap selanjutnya dapat dilakukan secara lebih akurat dan efisien. Secara matematis, bobot TF-IDF dihitung sebagai hasil perkalian

antara *Term Frequency* (TF) dan *Inverse Document Frequency* (IDF) (Manning et al., 2008).

4.2.3.3 N-Gram

Setelah proses pembobotan TF-IDF dilakukan, tahap berikutnya adalah pembentukan *N-Gram* untuk mempertahankan konteks dan urutan kata pada nama produk. Pada penelitian ini digunakan parameter *ngram_range*=(1,2), sehingga fitur yang dibentuk terdiri atas *unigram* dan *bigram*. Penggunaan *N-Gram* bertujuan untuk menangkap hubungan antar token yang saling berkaitan, terutama pada nama produk elektronik yang sering kali terdiri atas kombinasi kode model, seri, dan spesifikasi tertentu (Jurafsky & Martin, 2023). Tabel 4.X dapat dilihat sebagai contoh mendetail.

Tabel 4.8 Contoh Pembentukan N-Gram
ASUS RTX5070 OC

Unigram	Bigram
• ASUS • RTX5070 • OC	• ASUS RTX5070 • RTX5070 OC

4.2.3.4 Cosine Similarity

Sebelum proses perhitungan kemiripan dilakukan, terlebih dahulu diterapkan proses *candidate selection*, yaitu dengan membatasi kandidat pencocokan hanya pada produk yang memiliki atribut *brand* yang sama. Pendekatan ini dipilih karena *brand* merupakan salah satu atribut identitas utama pada produk elektronik, sehingga dapat memperkecil ruang pencarian sekaligus mengurangi kemungkinan terjadinya *false matching* (Li et al., 2020).

Selanjutnya, nilai *Cosine Similarity* dihitung antara produk internal DB Klik dengan seluruh kandidat produk kompetitor yang memiliki *brand* yang sama. Dari hasil perhitungan tersebut, dipilih lima kandidat dengan nilai kemiripan tertinggi (*Top-5 Similarity*) sebagai calon pasangan produk. Penggunaan pendekatan *Top-K retrieval* bertujuan untuk mempertahankan kandidat dengan tingkat kemiripan paling tinggi sekaligus mengurangi kompleksitas proses pencarian pada dataset yang berukuran besar (Manning et al., 2008). Setelah itu, dilakukan proses penyaringan akhir menggunakan nilai ambang batas (*similarity threshold*) untuk menentukan apakah suatu pasangan produk dapat dikategorikan sebagai hasil *matching*.

Secara matematis, nilai *Cosine Similarity* antara dua vektor TF-IDF,

$$\text{Cosine Similarity}(A, B) = \frac{A \cdot B}{\|A\| \times \|B\|}$$

atau jika ingin dituliskan secara lebih rinci:

$$\text{Cosine Similarity}(A, B) = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \times \sqrt{\sum_{i=1}^n B_i^2}}$$

Catatan:


- A = vektor TF-IDF dari produk pertama;
- B = vektor TF-IDF dari produk kedua;
- $A \cdot B$ = hasil perkalian titik (*dot product*) antara kedua vektor;
- $\|A\|$ = norma atau panjang vektor A ;
- $\|B\|$ = norma atau panjang vektor B ;
- n = jumlah dimensi atau jumlah fitur pada vektor TF-IDF.
- Nilai *Cosine Similarity* berada pada rentang:
- $0 \leq \text{Cosine Similarity}(A, B) \leq 1$

di mana:

nilai mendekati 0 menunjukkan kedua produk memiliki tingkat kemiripan yang rendah;

nilai mendekati 1 menunjukkan kedua produk memiliki tingkat kemiripan yang sangat tinggi.

Pada penelitian ini, nilai *Cosine Similarity* digunakan untuk menentukan tingkat kesamaan antara nama produk internal DB Klik dan produk kompetitor. Pasangan produk dengan nilai kemiripan tertinggi yang memenuhi batas *threshold* kemudian ditetapkan sebagai hasil *product matching*.



Gambar 4.16 Distribusi similarity score

Dominasi nilai *similarity* yang mendekati 1,0 mengindikasikan bahwa proses *preprocessing*, standarisasi merek, dan pembentukan representasi teks menggunakan TF-IDF berhasil mempertahankan

karakteristik utama produk sehingga meningkatkan akurasi proses pencocokan

4.2.4 Feature Engineer

Proses *feature engineering* dilakukan untuk mentransformasikan hasil *product matching* menjadi sekumpulan fitur yang dapat merepresentasikan kondisi pasar, performa penjualan, serta profitabilitas produk. Pada penelitian ini, fitur yang dibangun dikelompokkan ke dalam tiga kategori utama, yaitu *temporal features*, *competitive features*, dan *business features*. Pembentukan fitur berbasis domain (*domain-driven feature engineering*) dilakukan karena pemahaman terhadap karakteristik bisnis retail memiliki peran penting dalam meningkatkan kualitas analisis dan performa model prediksi (Kuhn & Johnson, 2019).

Tabel 4.9 Kategori Fitur yang Digunakan

Kategori Feature Variabel	
Temporal	Datetime_DB
Competitive	Harga_Komp_Min
	Harga_Komp_Mean
	Harga_Komp_Max
	Qty_Komp_Mean
	Qty_Komp_Max
	Similarity_Mean
	Jumlah_Kompetitor
Business	Harga_DB
	Qty_DB
	Omset_DB
	HPP
	Margin
	Margin_Pct

4.2.4.1 Temporal Features

Pada penelitian ini, atribut waktu *Datetime_DB* digunakan sebagai identitas periode transaksi dalam proses analisis. Berbeda dengan pendekatan *time series forecasting* yang memanfaatkan *lag features* atau *rolling statistics*, atribut waktu pada penelitian ini tidak diolah menjadi fitur prediktif, melainkan digunakan sebagai *grouping key* pada proses agregasi data. Penggunaan atribut waktu sebagai identitas periode bertujuan untuk menjaga konsistensi pencatatan transaksi dan memastikan bahwa setiap observasi merepresentasikan kondisi pasar pada periode yang sama.

4.2.4.2 Competitive Features

Competitive features merupakan fitur yang dibentuk berdasarkan informasi produk kompetitor hasil proses *product matching*. Fitur-fitur ini digunakan untuk merepresentasikan kondisi persaingan pasar yang dihadapi oleh setiap produk internal CV DB Klik.

Variabel *Harga_Komp_Min* dihitung untuk merepresentasikan harga terendah yang ditawarkan oleh kompetitor pada suatu periode pengamatan. Fitur ini digunakan untuk mengidentifikasi batas bawah harga pasar dan memberikan informasi mengenai tingkat agresivitas kompetitor dalam melakukan penetapan harga.

Variabel *Harga_Komp_Mean* digunakan untuk menggambarkan rata-rata harga pasar dari seluruh kompetitor yang menjual produk serupa. Nilai ini berfungsi sebagai representasi kondisi harga pasar secara umum dan digunakan sebagai acuan dalam proses analisis harga kompetitif.

Variabel *Harga_Komp_Max* dihitung untuk mengetahui harga tertinggi yang ditawarkan oleh kompetitor. Informasi ini dapat digunakan untuk melihat rentang variasi harga pasar serta mengidentifikasi peluang penetapan harga yang lebih kompetitif.

Selain atribut harga, dibentuk pula fitur *Qty_Komp_Mean* dan *Qty_Komp_Max*. Variabel *Qty_Komp_Mean* digunakan untuk merepresentasikan rata-rata volume penjualan kompetitor, sedangkan *Qty_Komp_Max* digunakan untuk mengidentifikasi kompetitor dengan tingkat penjualan tertinggi pada produk yang sama.

Hasil proses *product matching* juga dimanfaatkan untuk membentuk fitur *Similarity_Mean*, yaitu rata-rata nilai *Cosine Similarity* dari seluruh pasangan produk yang berhasil dicocokkan. Fitur ini digunakan sebagai indikator tingkat keyakinan (*confidence score*) terhadap hasil pencocokan produk. Semakin tinggi nilai *similarity*, semakin besar kemungkinan bahwa produk yang dipasangkan merupakan produk yang identik.

Selain itu, dibentuk pula fitur *Jumlah_Kompetitor*, yaitu jumlah perusahaan kompetitor unik yang menjual produk yang sama. Fitur ini digunakan untuk menggambarkan tingkat persaingan pasar yang dihadapi oleh setiap produk.

4.2.4.3 Business Features

Business features merupakan fitur yang berasal dari data internal CV DB Klik dan digunakan untuk merepresentasikan kondisi penjualan serta profitabilitas perusahaan.

Variabel *Harga_DB* digunakan untuk merepresentasikan harga jual produk yang ditetapkan oleh perusahaan pada periode pengamatan. Variabel *Qty_DB* digunakan untuk menunjukkan jumlah produk yang berhasil terjual, sedangkan *Omset_DB*

digunakan untuk merepresentasikan total pendapatan yang dihasilkan dari penjualan produk tersebut.

Selain itu, digunakan pula variabel *Harga Pokok Penjualan (HPP)* sebagai representasi biaya dasar produk yang ditanggung perusahaan. Berdasarkan nilai HPP tersebut, dihitung fitur *Margin* dan *Margin_Pct* untuk menggambarkan keuntungan absolut dan persentase keuntungan yang diperoleh perusahaan pada setiap transaksi. Fitur-fitur bisnis ini digunakan untuk memastikan bahwa proses optimasi harga tidak hanya mempertimbangkan kondisi pasar, tetapi juga mempertahankan profitabilitas perusahaan.

4.2.5 Agregasi Data

4.2.5.1 Agregasi Data Produk DB Klik

Pada data internal CV DB Klik, proses agregasi dilakukan berdasarkan atribut *Datetime_DB*, *Nama_DB*, dan *Brand_DB*. Nilai *Harga_DB* dihitung menggunakan fungsi rata-rata (*mean*) untuk merepresentasikan harga produk pada periode pengamatan, sedangkan *Qty_DB* dan *Omset_DB* dijumlahkan (*sum*) untuk memperoleh total penjualan dan pendapatan pada periode tersebut. Pendekatan agregasi statistik ini umum digunakan untuk menghasilkan representasi data yang lebih ringkas tanpa kehilangan informasi utama (Kuhn & Johnson, 2019).

4.2.5.2 Agregasi Data Kompetitor

Data kompetitor berasal dari berbagai penjual yang menawarkan produk serupa dengan variasi harga dan jumlah penjualan yang berbeda. Oleh karena itu, dilakukan agregasi menggunakan beberapa ukuran statistik untuk mempertahankan informasi kondisi pasar. Pada atribut *Harga_Komp*, dihitung nilai minimum, rata-rata, dan maksimum untuk menggambarkan rentang harga pasar. Sementara itu, atribut *Qty_Komp* dihitung menggunakan nilai rata-rata dan maksimum untuk merepresentasikan kondisi penjualan kompetitor. Selain itu, dihitung pula rata-rata nilai *Similarity* sebagai indikator tingkat keyakinan hasil *product matching*, serta jumlah kompetitor unik (*Jumlah_Kompetitor*) menggunakan fungsi *count unique*.

4.2.5.2 Penggabungan Informasi Margin Produk

Setelah proses agregasi selesai dilakukan, dataset hasil agregasi digabungkan dengan data internal CV DB Klik yang berisi informasi *Harga Pokok Penjualan (HPP)*, *Margin*, dan *Margin_Pct*. Penambahan atribut HPP dilakukan untuk memastikan bahwa proses optimasi harga tidak hanya mempertimbangkan kondisi pasar, tetapi juga memperhatikan aspek profitabilitas perusahaan. Selanjutnya dilakukan proses validasi dan koreksi terhadap data harga yang berada di luar rentang kewajaran sebelum digunakan pada tahap *feature engineering*. Hasil akhir dari proses ini adalah dataset terintegrasi

yang memuat informasi penjualan internal, kondisi pasar, hasil *product matching*, jumlah kompetitor, serta informasi profitabilitas produk yang digunakan pada tahap pemodelan berikutnya.

4.2.6 Pemodelan (Random Forest)

Setelah proses *feature engineering* dan agregasi data selesai dilakukan, tahap selanjutnya adalah pembangunan model prediksi permintaan (*demand forecasting*) menggunakan algoritma Random Forest Regression. Model ini bertujuan untuk memprediksi jumlah permintaan produk berdasarkan informasi harga internal, kondisi pasar kompetitor, tingkat persaingan, serta indikator profitabilitas perusahaan.

Random Forest merupakan metode *ensemble learning* berbasis *decision tree* yang bekerja dengan membangun sejumlah pohon keputusan secara acak (*bootstrap aggregating*) dan kemudian menggabungkan hasil prediksi dari seluruh pohon untuk menghasilkan prediksi akhir yang lebih stabil dan akurat (Breiman, 2001). Pada beberapa penelitian terbaru, Random Forest terbukti memiliki performa yang baik dalam menangani data retail yang bersifat non-linear, memiliki interaksi antar variabel yang kompleks, serta relatif tahan terhadap masalah *overfitting* dibandingkan metode regresi konvensional (Shah et al., 2022; Hossain et al., 2024).

Pada penelitian ini, variabel target (*target variable*) yang diprediksi adalah jumlah permintaan produk (Qty_DB), sedangkan variabel prediktor terdiri atas fitur kompetitif dan fitur bisnis yang telah dibentuk pada tahap sebelumnya. Sebelum dilakukan pelatihan model, data terlebih dahulu dibagi menjadi data pelatihan (*training set* = 1221 produk) dan data pengujian (*testing set* = 306 produk) untuk mengevaluasi kemampuan generalisasi model.

4.2.6.1 Parameter Model

Tabel 4.10 Parameter Utama Random Forest Regression

Parameter	Nilai	Fungsi
n_estimators	200	Jumlah pohon keputusan yang dibangun
max_depth	10	Kedalaman maksimum setiap pohon
random_state	42	Menjamin reproduktibilitas hasil
n_jobs	-1	Memanfaatkan seluruh inti prosesor

Parameter n_estimators=200 dipilih untuk menghasilkan jumlah pohon yang cukup banyak sehingga dapat meningkatkan stabilitas prediksi. Sementara itu, max_depth=10 digunakan untuk membatasi kompleksitas pohon dan mengurangi risiko *overfitting*. Penggunaan random_state=42 bertujuan menjaga konsistensi hasil eksperimen, sedangkan n_jobs=-1 digunakan untuk mengoptimalkan proses komputasi dengan memanfaatkan seluruh *CPU core* yang tersedia (Probst et al., 2019).

4.2.6.2 Proses Pelatihan Model

Pada algoritma Random Forest, setiap pohon keputusan dibangun menggunakan sampel acak hasil proses *bootstrap sampling*. Selanjutnya, pada setiap node dilakukan pemilihan subset fitur secara acak untuk menentukan pemisahan terbaik (*best*

split). Prediksi akhir diperoleh melalui rata-rata hasil prediksi seluruh pohon keputusan yang terbentuk.

Secara matematis, prediksi Random Forest Regression dapat dinyatakan sebagai berikut:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T f_t(x)$$

dengan:

- $\hat{y}$ = nilai prediksi akhir,
- T = jumlah pohon keputusan,
- $f_t(x)$ = prediksi dari pohon keputusan ke- t .

Pendekatan *ensemble averaging* tersebut memungkinkan Random Forest menghasilkan prediksi yang lebih robust terhadap *noise* dan fluktuasi data dibandingkan penggunaan satu pohon keputusan tunggal (Zhang et al., 2023).

4.2.6.3 Evaluasi Model

Kinerja model dievaluasi menggunakan tiga metrik evaluasi regresi, yaitu Mean Absolute Error (MAE), Root Mean Square Error (RMSE), dan Coefficient of Determination (R^2).

4.2.6.3.1 Mean Absolute Error (MAE)

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

4.2.6.3.2 Root Mean Square Error (RMSE)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$


4.2.6.3.3 Coefficient of Determination (R^2)

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Nilai MAE dan RMSE digunakan untuk mengukur besar kesalahan prediksi model, sedangkan nilai R^2 digunakan untuk mengukur kemampuan model dalam menjelaskan variasi data aktual. Semakin kecil nilai MAE dan RMSE serta semakin besar nilai R^2 , maka semakin baik performa model yang dihasilkan (Chicco et al., 2021).

4.6.2.4 Analisis Feature Importance

Untuk memahami faktor-faktor yang paling berpengaruh terhadap prediksi permintaan produk, dilakukan analisis *feature importance* pada model Random Forest Regression. Analisis ini bertujuan untuk mengukur kontribusi relatif setiap variabel prediktor terhadap proses pembentukan keputusan pada seluruh pohon (*decision trees*) dalam model. Pada algoritma Random Forest, nilai *feature importance* dihitung berdasarkan rata-rata penurunan impurity (*Mean Decrease in Impurity*) yang dihasilkan oleh setiap fitur selama proses pelatihan model (Breiman, 2001; Probst et al., 2019).



Gambar 4.17 Feature Importance Analysis

Hasil analisis menunjukkan bahwa variabel Jumlah_Kompetitor memiliki tingkat kepentingan paling tinggi dengan nilai *feature importance* sebesar 0,3768. Temuan ini mengindikasikan bahwa jumlah kompetitor yang menjual produk yang sama merupakan faktor utama yang memengaruhi permintaan produk pada industri retail elektronik. Semakin banyak kompetitor yang tersedia di pasar, maka perilaku permintaan terhadap suatu produk cenderung mengalami perubahan yang signifikan akibat meningkatnya persaingan harga dan variasi pilihan produk yang tersedia bagi konsumen.

Variabel dengan kontribusi terbesar berikutnya adalah Max_Qty_Komp dengan nilai *feature importance* sebesar 0,1493. Hasil ini menunjukkan bahwa volume penjualan tertinggi yang dicapai oleh kompetitor dapat menjadi indikator kuat terhadap potensi permintaan pasar suatu produk. Selain itu, variabel Margin_Rp (0,0712), Max_Harga_Komp (0,0612), dan Avg_Qty_Komp (0,0603) juga memberikan kontribusi yang cukup besar dalam proses prediksi. Temuan tersebut mengindikasikan bahwa prediksi permintaan tidak hanya dipengaruhi oleh faktor internal perusahaan, tetapi juga sangat dipengaruhi oleh kondisi persaingan pasar dan perilaku kompetitor.

Secara umum, hasil analisis *feature importance* menunjukkan bahwa variabel berbasis kompetisi (*competitive features*) memiliki kontribusi yang lebih dominan dibandingkan variabel bisnis internal. Hal ini memperkuat asumsi bahwa pada industri retail elektronik, dinamika pasar dan aktivitas kompetitor merupakan faktor utama yang memengaruhi perubahan permintaan produk.

4.2.7 Perhitungan Optimasi Harga

Setelah model *Random Forest Regression* berhasil dibangun, tahap selanjutnya adalah melakukan optimasi harga untuk memperoleh rekomendasi harga yang mampu menghasilkan keuntungan maksimum. Berbeda dengan pendekatan optimasi harga konvensional yang mengasumsikan bahwa permintaan bersifat tetap, pada penelitian ini optimasi dilakukan dengan mempertimbangkan perubahan permintaan akibat perubahan harga. Oleh karena itu, pendekatan yang digunakan adalah *price simulation*, yaitu melakukan simulasi berbagai kandidat harga dan memprediksi kembali permintaan untuk setiap kandidat harga tersebut menggunakan model *Random Forest* yang telah dilatih sebelumnya.

Pendekatan simulasi harga dipilih karena mampu merepresentasikan perilaku pasar yang lebih realistis, di mana perubahan harga suatu produk akan memengaruhi permintaan konsumen dan pada akhirnya memengaruhi profitabilitas perusahaan (Ferreira et al., 2016; Cohen et al., 2020).

4.2.7.1 Perhitungan Profit Aktual

Sebelum dilakukan proses optimasi harga, terlebih dahulu dihitung nilai keuntungan aktual (*actual profit*) dari setiap produk. Nilai keuntungan aktual digunakan sebagai nilai pembanding (*baseline*) untuk mengevaluasi apakah rekomendasi harga yang dihasilkan mampu meningkatkan keuntungan perusahaan dibandingkan kondisi saat ini.

Perhitungan profit aktual dilakukan berdasarkan selisih antara harga jual produk dengan Harga Pokok Penjualan (HPP), kemudian dikalikan dengan jumlah produk yang berhasil terjual pada periode pengamatan.

$$Profit = (Harga\ Jual - HPP) \times Qty$$

dengan:

- *Harga Jual* = harga produk yang diterapkan perusahaan,
- *HPP* = Harga Pokok Penjualan,
- *Qty* = jumlah produk yang terjual.

Nilai profit aktual ini kemudian digunakan sebagai acuan untuk membandingkan hasil optimasi harga pada tahap berikutnya.

4.2.7.2 Simulasi Kandidat Harga

Pada penelitian ini, optimasi harga dilakukan menggunakan pendekatan *price simulation*. Untuk setiap produk dibentuk sejumlah kandidat harga mulai dari 20% lebih rendah hingga 20% lebih tinggi dibandingkan harga awal dengan interval perubahan sebesar 2%. Dengan demikian, setiap produk memiliki 21 kandidat harga yang akan dievaluasi selama proses optimasi.

Tabel 4.11 Parameter Simulasi Harga

Parameter	Nilai
Harga minimum	80% dari harga awal
Harga maksimum	120% dari harga awal
Interval	2%
Jumlah simulasi	21
Margin minimum	3%

Sebagai ilustrasi, apabila harga awal suatu produk adalah Rp100.000, maka kandidat harga yang dihasilkan dapat berupa:

Tabel 4.12 Ilustrasi Harga

Faktor	Harga
80%	Rp80.000
82%	Rp82.000
84%	Rp84.000
...	...
118%	Rp118.000
120%	Rp120.000

Proses simulasi ini memungkinkan model mengevaluasi berbagai skenario harga sehingga dapat diperoleh harga yang memberikan keuntungan maksimum.

4.2.7.3 Prediksi Permintaan Menggunakan Random Forest

Setelah kandidat harga dibentuk, dilakukan pembaruan terhadap seluruh variabel yang dipengaruhi oleh perubahan harga. Pada penelitian ini, fitur yang diperbarui meliputi:

- Price_Gap_Min
- Price_Gap_Avg
- Price_Ratio

Selanjutnya, data yang telah diperbarui dimasukkan kembali ke dalam model *Random Forest Regression* yang telah dilatih sebelumnya untuk menghasilkan prediksi permintaan baru pada setiap kandidat harga.

Pendekatan ini memungkinkan perubahan harga untuk memengaruhi permintaan secara dinamis, sehingga simulasi yang dihasilkan lebih mendekati kondisi pasar sebenarnya dibandingkan pendekatan optimasi statis (Talluri & van Ryzin, 2004; Cohen et al., 2020).

4.2.7.4 Perhitungan Profit Kandidat

Setelah diperoleh prediksi permintaan baru, dilakukan perhitungan ulang terhadap margin dan profit untuk setiap

kandidat harga. Persentase margin dihitung menggunakan persamaan:

$$\text{Margin}(\%) = \frac{\text{Harga} - \text{HPP}}{\text{Harga}} \times 100\%$$

Sedangkan profit dihitung menggunakan persamaan:

$$\text{Profit} = (\text{Harga} - \text{HPP}) \times \text{Prediksi Qty}$$

Untuk menjaga profitabilitas perusahaan, diterapkan batas minimum margin sebesar 3%. Kandidat harga yang menghasilkan margin di bawah batas tersebut akan dieliminasi dari proses optimasi.

Sebagai contoh, hasil simulasi dapat digambarkan pada Tabel berikut.

Tabel 4.13 Hasil Simulasi Harga

Harga	Pred Qty	Margin	Profit
98.000	112	4%	3,2 juta
100.000	108	5%	3,4 juta
102.000	101	6%	3,5 juta

Penerapan batas margin minimum ini bertujuan untuk memastikan bahwa rekomendasi harga yang dihasilkan tetap berada dalam koridor profitabilitas perusahaan.

4.2.7.5 Penentuan Harga Optimal

Setelah seluruh kandidat harga selesai dievaluasi, dipilih kandidat yang menghasilkan nilai profit terbesar dengan tetap memenuhi batas minimum margin sebesar 3%. Pada tahap ini, seluruh kandidat harga yang memiliki margin di bawah batas minimum akan dieliminasi. Selanjutnya, kandidat dengan profit tertinggi ditetapkan sebagai harga optimal. Pendekatan ini memungkinkan perusahaan memperoleh harga yang tidak hanya kompetitif terhadap pasar, tetapi juga mampu menghasilkan keuntungan maksimum berdasarkan estimasi permintaan yang diperoleh dari model *Random Forest*.

4.2.8 Pembuatan Dashboard dan Website Simulasi

4.2.8.1 Arsitektur Sistem

Tabel 4.14 Spesifikasi Sistem


Komponen	Teknologi
Backend	Python
Frontend	HTML

Komponen	Teknologi
Styling	CSS
Interaksi	JavaScript
Framework API	FastAPI
Machine Learning	Random Forest Regression
Model Storage	Joblib
Dashboard	Looker Studio

Arsitektur sistem yang dibangun pada penelitian ini menggunakan pendekatan *client-server architecture*. Sistem terdiri atas antarmuka pengguna (*frontend*) yang dibangun menggunakan HTML, CSS, dan JavaScript, serta *backend* yang dikembangkan menggunakan framework FastAPI berbasis Python. Backend bertugas melakukan komunikasi dengan model *Random Forest Regression*, menjalankan simulasi optimasi harga, serta mengembalikan hasil prediksi kepada pengguna.

Pada implementasinya, pengguna melakukan interaksi melalui antarmuka website. Selanjutnya data yang dikirimkan pengguna diproses oleh API menggunakan FastAPI. API kemudian memanggil model *Random Forest* yang telah disimpan menggunakan *Joblib*, melakukan prediksi permintaan, menjalankan simulasi optimasi harga, dan menghasilkan rekomendasi harga optimal beserta estimasi profit yang diperoleh.

Implementasi arsitektur berbasis API dipilih karena mampu memisahkan proses komputasi model dengan tampilan antarmuka



pengguna sehingga sistem menjadi lebih fleksibel, mudah dikembangkan, dan dapat digunakan kembali pada berbagai platform (Ramírez, 2021).

Gambar 4.18 Arsitektur Sistem Optimasi Harga

4.2.8.2 Dashboard Monitoring


Selain sistem simulasi harga berbasis web, pada penelitian ini juga dikembangkan dashboard monitoring menggunakan Looker Studio sebagai media visualisasi data bisnis. Dashboard ini berfungsi sebagai pelengkap dari sistem simulasi dan prediksi yang telah dibangun, dengan fokus pada pemantauan performa penjualan toko secara berkala (periode

bulan berjalan dibandingkan bulan sebelumnya) sehingga pihak manajemen dapat memantau dampak dari keputusan harga dan strategi penjualan terhadap kinerja bisnis secara nyata, tanpa perlu melakukan analisis manual terhadap data mentah.

Dashboard yang dibangun menampilkan berbagai indikator utama (Key Performance Indicators/KPI), seperti:

- Total omset penjualan beserta persentase perubahan (growth) dibandingkan periode sebelumnya,
- Total pelanggan (customer) beserta persentase perubahannya,
- Total produk terjual beserta persentase perubahannya,
- Biaya iklan pada periode berjalan dan periode sebelumnya,
- ACOS (Advertising Cost of Sales) sebagai indikator efisiensi belanja iklan terhadap omset,
- Perbandingan omset per kategori produk antarperiode dalam bentuk grafik batang,
- Rincian analisis per kategori dan per produk, meliputi omset, growth rate value (Rp dan %), serta growth rate kuantitas (unit dan %).

Melalui KPI tersebut, dashboard memungkinkan pengguna untuk mengidentifikasi secara cepat kategori atau produk mana yang mengalami peningkatan maupun penurunan penjualan, serta menilai efisiensi biaya iklan terhadap omset yang dihasilkan. Dengan demikian, dashboard ini berperan sebagai lapisan monitoring lanjutan setelah harga produk disesuaikan melalui sistem simulasi berbasis web, di mana hasil penyesuaian harga tersebut pada akhirnya dapat tercermin pada pergerakan omset, jumlah produk terjual, dan margin yang ditampilkan secara berkala di dashboard ini. Penggunaan dashboard visual interaktif semacam ini memungkinkan pengguna memperoleh informasi secara cepat dan intuitif tanpa perlu melakukan proses analisis data secara manual.



Gambar 4.19 Tampilan Dashboard Looker (Per Bulan Mei)

Analisa Per Produk									
Produk	Omset Mei	Omset April	GR Value (Rp)	GR Value (%)	Produk Mei	Produk April	GR Qty (Unit)	GR Qty (%)	
APC BK2200M-MS(SVG2200)-GR Easy UPS 2200VA 1200W	110.314.186	135.065.488	-24.751.302	-0,18	38	46	-8	-17,39%	
Monitor VIEWSONIC VA22E2-H 22" FHD VA 100Hz 5ms Ad...	97.816.529	60.166.124	37.650.405	0,63	100	61	39	63,93%	
Logitech B100 Mouse Wired 1000 DPI	89.728.342	85.396.029	4.332.313	0,05	1.545	1.489	56	3,76%	
PHILIPS LED Monitor 221V8Lb 22" VA FHD 100Hz 1ms Ada...	87.903.209	94.312.369	-6.409.160	-0,07	87	94	-7	-7,45%	
Spc Led Monitor Sm-22 21.5inch 60Hz Ips Fhd Hdmi - Led	81.931.650	161.400.400	-79.468.750	-0,49	111	228	-117	-51,32%	
QWERTY LED Monitor Office QM-190VH 19" IPS HD 75Hz	76.967.862	92.831.702	-15.863.840	-0,17	136	165	-29	-17,58%	
Epson Printer L121 Eco Tank - Ecotank L121 A4 Ink Tank Pr...	72.132.410	14.697.450	57.434.960	3,91	44	9	35	388,89%	
Total keseluruhan	6.709.386.095	8.019.822.060	-1.310.445.965	-0,16	12.603	16.388	-3.785	-23,1%	

Gambar 4.20 Tampilan Dashboard Looker (Per Bulan Mei) (2)

4.2.8.3 Website Simulasi Optimasi Harga

Website simulasi optimasi harga dikembangkan menggunakan HTML, CSS, dan JavaScript sebagai antarmuka pengguna, sedangkan proses prediksi permintaan dan optimasi harga dijalankan pada sisi backend menggunakan Python dan FastAPI. Website ini dirancang agar pengguna dapat melakukan simulasi harga secara mudah tanpa perlu memahami proses perhitungan yang dilakukan oleh model.

Pada sistem yang dibangun, pengguna dapat memilih produk yang tersedia, memasukkan skenario perubahan harga, serta memperoleh hasil simulasi berupa estimasi permintaan, profit, dan rekomendasi harga optimal. Dengan demikian, proses pengambilan keputusan harga dapat dilakukan secara lebih cepat dan berbasis data.

Implementasi antarmuka berbasis web dipilih karena memiliki tingkat aksesibilitas yang tinggi serta memungkinkan sistem digunakan oleh pengguna non-teknis.

Simulasi Harga Produk

Pilih Produk

Access Point D-Link DAP-X2810 AX1800 Dual Band Wifi 6

Tampilkan Produk

Access Point D-Link DAP-X2810 AX1800 Dual Band Wifi 6

Brand : D-LINK

Harga : Rp 5.621.000

HPP : Rp 5.000.001

Qty : 0

Margin : 11,05%

Kompetitor : 1

Harga Baru

5500000

Simulasikan

Carilah Harga Optimal

Hasil Simulasi

Prediksi Qty

6.22

Revenue

Rp 34.225.587

Profit

Rp 3.111.411

Margin

9.09%

Rekomendasi Harga Optimal

Harga Optimal

Rp 6.745.200

Profit Saat Ini : Rp 0

Profit Optimal : Rp 15.930.941

Profit Improvement : Rp 15.930.941

Gambar 4.21 Tampilan Dashboard Looker (Per Bulan Mei)

4.2.8.4 Implementasi Model Random Forest



Gambar 4.22 Alur kerja prediksi demand dan hitung profit

Model *Random Forest Regression* yang telah selesai dilatih kemudian disimpan dalam format *.pkl* menggunakan pustaka *Joblib*. Penyimpanan model dilakukan agar proses pelatihan tidak perlu dilakukan kembali setiap kali sistem dijalankan sehingga waktu komputasi menjadi lebih efisien.

Pada saat pengguna melakukan simulasi harga, backend akan memuat (*load*) model *Random Forest* yang telah disimpan. Selanjutnya sistem melakukan pembaruan terhadap fitur-fitur yang dipengaruhi oleh perubahan harga, seperti *Price Gap*, *Price Ratio*, dan variabel kompetitif lainnya. Dataset hasil pembaruan tersebut kemudian digunakan sebagai input model untuk menghasilkan prediksi permintaan baru.

Pendekatan ini memungkinkan sistem menghasilkan simulasi permintaan yang bersifat dinamis sesuai dengan perubahan harga yang dilakukan pengguna.

4.2.8.5 Hasil Simulasi Optimasi Harga

Tahap akhir implementasi sistem adalah menampilkan hasil simulasi optimasi harga kepada pengguna. Hasil yang ditampilkan meliputi harga awal produk, harga rekomendasi hasil optimasi, estimasi permintaan baru, profit aktual, profit hasil optimasi, serta peningkatan profit yang diperoleh.

Sebagai contoh pada Gambar 4.X, ketika pengguna melakukan simulasi terhadap suatu produk dengan harga awal tertentu, sistem akan menghitung kembali permintaan berdasarkan model *Random Forest*, melakukan evaluasi terhadap seluruh kandidat harga, kemudian menampilkan harga yang menghasilkan keuntungan maksimum dengan tetap memenuhi batas margin minimum yang telah ditetapkan.

Dengan adanya fitur simulasi ini, pengguna dapat mengevaluasi berbagai skenario harga secara interaktif tanpa perlu melakukan perhitungan secara manual.

BAB V

KORELASI PROGRAM STUDI INDEPENDEN DENGAN KONVERSI MATA KULIAH

5.1 Kegiatan Studi Independen yang Dikembangkan

Kegiatan Studi Independen yang dilaksanakan bersama CV DB Klik difokuskan pada pengembangan sistem *Price Optimization* berbasis *Machine Learning* untuk mendukung proses penentuan harga produk pada industri ritel teknologi informasi. Kegiatan ini dilaksanakan sebagai upaya untuk mengatasi permasalahan nyata yang dihadapi perusahaan, yaitu proses penetapan harga yang masih dilakukan secara konvensional dan belum sepenuhnya memanfaatkan data historis penjualan, kondisi pasar, serta informasi harga kompetitor sebagai dasar pengambilan keputusan.

Selama pelaksanaan studi independen, telah berhasil dikembangkan sebuah sistem terintegrasi yang menggabungkan proses pengumpulan data, *product matching*, *feature engineering*, prediksi permintaan (*demand forecasting*), optimasi harga, visualisasi data, serta implementasi sistem berbasis web. Data yang digunakan berasal dari berbagai sumber, meliputi data internal perusahaan berupa data produk, data penjualan historis, dan Harga Pokok Penjualan (HPP), serta data eksternal berupa data kompetitor yang diperoleh melalui proses *web scraping*. Seluruh data tersebut kemudian diintegrasikan untuk membentuk dataset yang digunakan dalam proses analisis dan pemodelan.

Pada tahap pengolahan data, dilakukan proses *product matching* menggunakan pendekatan *Natural Language Processing* (NLP) dengan kombinasi metode TF-IDF, N-Gram, dan Cosine Similarity untuk menyelaraskan produk internal perusahaan dengan produk kompetitor yang memiliki perbedaan format penulisan. Selanjutnya dilakukan proses *feature engineering* untuk membentuk berbagai variabel bisnis, kompetitif, dan operasional yang digunakan dalam pembangunan model prediksi permintaan menggunakan algoritma *Random Forest Regression*. Hasil prediksi permintaan tersebut kemudian diintegrasikan ke dalam sistem simulasi optimasi harga untuk menghasilkan rekomendasi harga yang mempertimbangkan perubahan permintaan, margin keuntungan, serta kondisi pasar.

Sebagai luaran akhir, kegiatan studi independen ini berhasil menghasilkan sebuah *prototype Decision Support System* berbasis web yang dibangun menggunakan HTML, CSS, JavaScript, Python, dan FastAPI, serta dilengkapi dengan dashboard monitoring menggunakan Looker Studio. Sistem yang dikembangkan memungkinkan pengguna untuk melakukan simulasi perubahan harga, memperoleh estimasi permintaan, menghitung proyeksi profit, serta mendapatkan rekomendasi harga optimal secara interaktif. Dengan demikian, kegiatan studi independen ini tidak hanya menghasilkan luaran akademis, tetapi juga menghasilkan solusi yang aplikatif dan berpotensi mendukung proses pengambilan keputusan bisnis berbasis data di lingkungan industri.

5.2 Tujuan Pengembangan

- Meningkatkan kapasitas mahasiswa dalam menerapkan ilmu data analytics, machine learning, dan pengembangan sistem berbasis web secara praktis.
- Menghasilkan solusi nyata berupa sistem optimasi harga yang relevan dengan kebutuhan mitra industri.

- Memberikan kontribusi dalam peningkatan efisiensi dan kualitas pengambilan keputusan bisnis di perusahaan.
- Menjadi dasar untuk konversi capaian pembelajaran pada mata kuliah yang relevan

5.3 Langkah-langkah Pengembangan

5.3.1 Identifikasi Masalah dan Kebutuhan Mitra

Mahasiswa melakukan observasi dan diskusi dengan pihak mitra untuk memahami proses bisnis yang berjalan, khususnya dalam penentuan harga produk serta kendala yang dihadapi. .

5.3.2 Perumusan Gagasan dan Desain Solusi

Mahasiswa melakukan observasi dan diskusi dengan pihak mitra untuk memahami proses bisnis yang berjalan, khususnya dalam penentuan harga produk serta kendala yang dihadapi.

5.3.3 Validasi dan Kolaborasi dengan Mitra

Solusi yang dirancang akan dikonsultasikan dengan mitra untuk memperoleh masukan serta memastikan kesesuaian dengan kebutuhan perusahaan

5.3.4 Implementasi atau Simulasi Lapangan

Sistem yang dikembangkan akan diimplementasikan dalam bentuk aplikasi berbasis web dan diuji menggunakan data yang tersedia untuk menghasilkan rekomendasi harga produk.

5.3.5 Evaluasi dan Dokumentasi Hasil

Dilakukan evaluasi terhadap kinerja sistem serta manfaat yang dihasilkan bagi mitra. Hasil dari studi ini kemudian didokumentasikan dalam bentuk laporan yang dapat digunakan untuk konversi mata kuliah.

Table 4.15 Kegiatan Proyek dan Studi Bulan Maret

BULAN : MARET					
MINGGU	POSISI	TOPIK	DURASI (jam)	TARGET	METODE
3	Semua Posisi	Perkenalan lingkungan dan tugas selama magang	54	Peserta siap melakukan magang secara luring	Sesi Induksi dan FGD secara luring

Table 4.16 Kegiatan Proyek dan Studi Bulan April

BULAN : APRIL					
MINGGU	POSISI	TOPIK	DURASI (jam)	TARGET	METODE
1	<i>Data Analyst Intern</i>	Pengumpulan data (internal & scraping kompetitor)	54	Dataset awal terkumpul	<i>Scraping, data collection</i>
2	<i>Data Analyst Intern</i>	Data Preprocessing	54	Data bersih dan siap analisis	Data cleaning, transformasi
3	<i>Data Analyst Intern</i>	<i>Exploratory Data Analysis (EDA)</i>	54	Mengetahui pola dan karakteristik data	EDA, Visualisasi
4	<i>Data Analyst Intern</i>	Analisis tren data (<i>time series</i>)	54	Mengetahui pola tren penjualan	Time series analysis

Table 4.17 Kegiatan Proyek dan Studi Bulan Mei

BULAN : MEI					
MINGGU	POSISI	TOPIK	DURASI (jam)	TARGET	METODE
1	<i>Data Analyst Intern</i>	Feature Engineering	54	Fitur penting terbentuk	Feature engineering
2	<i>Data Analyst Intern</i>	Analisis hubungan variabel	54	Insight hubungan harga & demand	Analisis korelasi

BULAN : MEI					
MINGGU	POSISI	TOPIK	DURASI (jam)	TARGET	METODE
3	<i>Data Analyst Intern</i>	Finalisasi fitur	54	Dataset final siap modeling	Evaluasi fitur
4	<i>Data Analyst Intern</i>	Penentuan algoritma optimasi	54	Metode optimasi ditentukan	Studi literatur, eksperimen

Table 4.18 Kegiatan Proyek dan Studi Bulan Juni

BULAN : JUNI					
MINGGU	POSISI	TOPIK	DURASI (jam)	TARGET	METODE
1	<i>Data Analyst Intern</i>	Implementasi model	54	Model awal terbentuk	<i>Coding, modeling</i>
2	<i>Data Analyst Intern</i>	Evaluasi model	54	Model optimal	Validasi, tuning
3	<i>Data Analyst Intern</i>	Finalisasi model	54	Model siap deploy	Testing
4	<i>Data Analyst Intern</i>	Pengembangan sistem web	54	Sistem awal terbentuk	Streamlit development

5.3.6 Dampak Studi Independen yang Diusulkan

5.3.6.1 Dampak Bagi Mitra

- Peningkatan Efisiensi Penentuan Harga

Sistem optimasi harga berbasis data membantu perusahaan dalam menentukan harga produk secara otomatis dan terstruktur, sehingga mengurangi ketergantungan pada proses manual atau intuisi.

- Pengambilan Keputusan Berbasis Data
Mitra dapat mengambil keputusan bisnis yang lebih akurat karena didukung oleh analisis data penjualan, tren permintaan, serta perbandingan harga dengan kompetitor.
- Peningkatan Daya Saing Perusahaan
Dengan mempertimbangkan harga kompetitor, perusahaan dapat menetapkan harga yang lebih kompetitif di pasar, sehingga meningkatkan peluang penjualan.
- Pemahaman Pola Penjualan dan Perilaku Pasar
Melalui visualisasi data dan analisis, perusahaan dapat memahami tren penjualan, produk yang laris (*fast moving*), serta pola permintaan konsumen.
- Peningkatan Profitabilitas
Penentuan harga yang optimal memungkinkan perusahaan untuk memaksimalkan keuntungan tanpa mengorbankan daya saing di pasar.

5.3.6.1 Dampak Bagi Mahasiswa

- Peningkatan Keterampilan Teknis (*Hard Skills*)
Mahasiswa memperoleh pengalaman dalam:
 - scraping data
 - data preprocessing
 - feature engineering
 - analisis data
 - pengembangan sistem berbasis web
- Penerapan Ilmu Secara Nyata di Dunia Industri
Mahasiswa dapat mengimplementasikan konsep yang dipelajari di perkuliahan seperti data analytics, machine learning, dan visualisasi data dalam kasus nyata di perusahaan.
- Penguatan Kemampuan Problem Solving
Mahasiswa dilatih untuk menyelesaikan permasalahan nyata yang kompleks, seperti menentukan metode optimasi harga yang sesuai dengan kondisi data dan kebutuhan bisnis.
- Pengembangan *Soft Skills* Profesional
Selama studi independen, mahasiswa juga mengembangkan:
 - kemampuan komunikasi dengan mentor/mitra
 - kemampuan kerja tim
 - adaptasi terhadap lingkungan kerja profesional
- Kesiapan Menghadapi Dunia Kerja
Pengalaman langsung dalam proyek industri membuat mahasiswa lebih siap secara kompetensi dan mental untuk memasuki dunia kerja, khususnya di bidang data analyst.

5.4 Relevansi dengan Mata Kuliah Konversi

5.4.1 Perencanaan Program Studi Independen (2 SKS)

Sebelum pelaksanaan proyek dimulai, dilakukan proses perencanaan yang meliputi identifikasi permasalahan bisnis di CV DB Klik, penyusunan ruang lingkup proyek, penetapan tujuan, serta penentuan metodologi yang akan digunakan. Perencanaan ini dituangkan dalam rancangan alur kerja (*end-to-end pipeline*) yang mencakup tahapan pengumpulan data, *product matching*, *feature engineering*, *demand forecasting*, optimasi harga, visualisasi, hingga *deployment* sistem berbasis web. Selain itu, pada tahap awal ini juga dilakukan identifikasi sumber data yang relevan, penentuan

algoritma yang sesuai dengan karakteristik data retail IT, serta penyusunan jadwal pelaksanaan proyek secara terstruktur. Keseluruhan proses perencanaan ini secara langsung merepresentasikan capaian pembelajaran mata kuliah Perencanaan Program Studi Independen, yaitu kemampuan mahasiswa dalam merancang program kerja yang terukur, sistematis, dan berorientasi pada penyelesaian masalah nyata di industri.

5.4.2 Evaluasi Program Studi Independen (2 SKS)

Evaluasi dilakukan secara menyeluruh terhadap setiap tahapan proyek yang telah direncanakan. Pada tahap *product matching*, evaluasi dilakukan dengan mengukur *coverage* hasil pencocokan produk dan rata-rata nilai *similarity score* yang dihasilkan. Pada tahap pemodelan, evaluasi mencakup pengukuran performa model *Random Forest Regression* menggunakan metrik MAE, RMSE, dan R^2 , baik pada data latih maupun data uji, serta perbandingan performa antara dua varian model yang dikembangkan. Selain evaluasi teknis, dilakukan pula evaluasi terhadap keterbatasan sistem, khususnya terkait hasil fungsi optimasi harga yang belum menghasilkan nilai *Profit_Optimal* secara konsisten pada seluruh data. Temuan-temuan dari proses evaluasi ini kemudian didokumentasikan sebagai dasar rekomendasi pengembangan sistem lebih lanjut. Proses evaluasi yang bersifat kritis, terukur, dan reflektif ini secara langsung merepresentasikan kompetensi yang dikembangkan dalam mata kuliah Evaluasi Program Studi Independen.

5.4.3 Tata Tulis Ilmiah (2 SKS)

Seluruh proses dan hasil pelaksanaan studi independen didokumentasikan dalam bentuk laporan akhir ilmiah yang disusun menggunakan kaidah penulisan akademis. Laporan ini mencakup struktur ilmiah yang lengkap mulai dari latar belakang, tinjauan pustaka, metode penelitian, hasil dan pembahasan, hingga kesimpulan dan rekomendasi. Penulisan laporan dilakukan dengan menggunakan gaya sitasi dan daftar pustaka dalam format *Harvard style*, mengacu pada sumber-sumber ilmiah yang relevan dan terverifikasi. Selain itu, dalam laporan ini juga disajikan tabel, gambar, dan visualisasi hasil analisis yang dilengkapi dengan keterangan dan interpretasi yang sistematis. Kemampuan menyusun laporan ilmiah yang terstruktur, konsisten, dan sesuai dengan konvensi akademis ini secara langsung mencerminkan kompetensi yang dikembangkan dalam mata kuliah Tata Tulis Ilmiah.


5.4.4 Berpikir Kreatif (2 SKS)

Pengembangan sistem *Price Optimization* di CV DB Klik menuntut kemampuan berpikir kreatif dalam menerjemahkan permasalahan bisnis yang kompleks menjadi solusi teknis yang implementatif. Kreativitas diterapkan dalam beberapa aspek, di antaranya: perancangan pendekatan *product matching* dua tahap yang menggabungkan pencocokan berbasis aturan (*rule-based*) dengan metode NLP berbasis TF-IDF dan *cosine similarity* untuk meningkatkan *coverage* pencocokan produk; perancangan fitur-fitur rekayasa (*feature engineering*) baru yang tidak tersedia secara langsung pada data mentah, seperti *price gap*, *price ratio*, *rolling mean*, dan


lag features; serta integrasi model prediksi permintaan ke dalam mekanisme simulasi grid-search harga untuk menemukan titik harga dengan profit optimal. Seluruh pendekatan kreatif ini merupakan hasil dari proses identifikasi masalah, eksplorasi alternatif solusi, dan pemilihan pendekatan yang paling sesuai dengan kebutuhan dan keterbatasan data yang tersedia, yang secara langsung merepresentasikan kompetensi berpikir kreatif dalam konteks pemecahan masalah dunia nyata.

5.4.5 Pemrograman Berbasis Web (3 SKS)

Salah satu luaran utama proyek ini adalah pengembangan aplikasi web simulasi harga yang dibangun menggunakan HTML, CSS, dan JavaScript pada sisi *frontend*, serta FastAPI berbasis Python sebagai layanan *backend*. FastAPI digunakan untuk mengekspos model *Random Forest* yang telah disimpan dalam format *.pkl* melalui *endpoint* API, sehingga antarmuka web dapat menerima input parameter harga dari pengguna dan mengembalikan estimasi permintaan serta simulasi profit secara dinamis. Selain itu, digunakan pula *library* Chart.js untuk menampilkan hasil simulasi dalam bentuk grafik interaktif di halaman web. Sistem ini kemudian di-*deploy* menggunakan platform Netlify agar dapat diakses secara daring oleh pengguna bisnis tanpa perlu menjalankan kode pemrograman secara manual. Keseluruhan proses pengembangan aplikasi web ini, mulai dari perancangan antarmuka, pengembangan API *backend*, integrasi model *machine learning*, hingga *deployment*, secara langsung merepresentasikan kompetensi yang dikembangkan dalam mata kuliah Pemrograman Berbasis Web.



Gambar 5.1 Dokumentasi visual studio code



Gambar 5.2 Tampilan FastAPI

a) User Requirement

Sebelum proses pengembangan sistem berbasis web dilakukan, tahap awal yang dilakukan adalah identifikasi kebutuhan pengguna (*user requirement*). Tahapan ini bertujuan untuk menentukan fitur, fungsi, dan karakteristik sistem yang akan dikembangkan agar sesuai dengan kebutuhan pengguna akhir.

Pengguna utama sistem optimasi harga ini adalah tim internal CV DB Klik, khususnya bagian manajemen dan penjualan yang membutuhkan sistem pendukung keputusan untuk melakukan simulasi perubahan harga produk. Sistem ini dirancang agar pengguna dapat memperoleh estimasi permintaan dan keuntungan secara otomatis tanpa perlu menjalankan proses analisis data maupun kode pemrograman secara manual.

Tabel 4.19 Identifikasi Pengguna Sistem

User	Deskripsi	Kebutuhan Pengguna
Tim Manajemen	Pengguna yang melakukan analisis terhadap strategi harga produk	Mebutuhkan informasi rekomendasi harga yang dapat meningkatkan profit berdasarkan data historis dan kondisi pasar
Tim Penjualan	Pengguna yang melakukan pemantauan harga dan performa produk	Mebutuhkan alat simulasi untuk mengetahui pengaruh perubahan harga terhadap estimasi penjualan dan keuntungan


Tabel 4.20 Kebutuhan Fungsional Sistem

Kode	Kebutuhan Fungsional	Deskripsi
FR-01	Input data simulasi harga	Sistem mampu menerima input berupa nama produk, harga jual, dan Harga Pokok Penjualan (HPP) yang dimasukkan oleh pengguna
FR-02	Prediksi permintaan produk	Sistem mampu menghasilkan estimasi jumlah permintaan (<i>demand prediction</i>) menggunakan model Random Forest Regression yang telah dilatih menggunakan data historis
FR-03	Perhitungan estimasi profit	Sistem mampu menghitung estimasi keuntungan berdasarkan kombinasi harga jual, HPP, dan hasil prediksi permintaan produk
FR-04	Optimasi harga produk	Sistem mampu memberikan rekomendasi harga optimal berdasarkan proses pencarian kandidat harga yang menghasilkan estimasi profit maksimum
FR-05	Visualisasi simulasi harga	Sistem mampu menampilkan grafik interaktif yang menggambarkan hubungan antara variasi harga, prediksi permintaan, dan estimasi profit
FR-06	Dashboard monitoring	Sistem mampu menyediakan visualisasi data penjualan dan hasil analisis melalui dashboard interaktif untuk membantu proses monitoring
FR-07	Akses sistem berbasis web	Sistem dapat diakses secara daring melalui browser tanpa memerlukan instalasi perangkat lunak tambahan

Tabel 4.21 Kebutuhan Non-Fungsional Sistem

Kode	Kebutuhan Non-Fungsional	Deskripsi
NFR-01	Usability (Kemudahan Penggunaan)	Sistem memiliki tampilan yang sederhana dan mudah dipahami sehingga pengguna non-teknis dapat melakukan simulasi harga secara mandiri
NFR-02	Performance (Kinerja Sistem)	Sistem mampu memberikan hasil prediksi dan rekomendasi harga dalam waktu singkat agar dapat digunakan dalam proses pengambilan keputusan
NFR-03	Responsiveness	Tampilan sistem dapat menyesuaikan berbagai ukuran perangkat seperti laptop, komputer, maupun perangkat lainnya
NFR-04	Availability	Sistem dapat digunakan secara daring sehingga pengguna dapat mengakses fitur simulasi harga ketika dibutuhkan
NFR-05	Maintainability	Sistem dirancang secara modular dengan pemisahan antara model machine learning, API, dan tampilan website sehingga lebih mudah dilakukan pengembangan atau pembaruan

b) Flow Diagram




Gambar 5.3 Flow Diagram Sistem Simulasi Harga Berbasis Web

- Alur mulai dari input pengguna (Frontend) → validasi → jika tidak valid kembali ke input dengan pesan error → jika valid dikirim ke Backend (FastAPI) → feature engineering → prediksi Random Forest → hitung simulasi profit → tampilkan hasil grafik → selesai

- Tiga warna berbeda untuk membedakan layer: hijau = Frontend (HTML/JS), biru = Backend (FastAPI Python), ungu = ML Model (Random Forest)
- Bentuk berlian untuk decision node validasi
- Dilengkapi keterangan/legend di bawah

c) ERD



Gambar 5.4 Gambar ERD

Dalam mengimplementasikan *data analytics pipeline* untuk optimasi harga di CV DB Klik, struktur penyimpanan data dirancang menggunakan prinsip relasional guna menghindari redundansi data dan menjaga konsistensi informasi. Basis data sistem ini dibagi menjadi dua kategori utama, yaitu tabel induk (*master data*) dan tabel transaksional (*transactional data*), yang saling terintegrasi melalui mekanisme *Primary Key* (PK) dan *Foreign Key* (FK).

Secara mendetail, berikut adalah spesifikasi dan fungsi dari masing-masing komponen tabel yang digunakan:

1. Tabel Master (M_Produk)

Tabel M_Produk bertindak sebagai entitas induk atau referensi utama di dalam sistem. Tabel ini menyimpan data atribut produk yang bersifat statis dan merepresentasikan identitas unik dari setiap barang, meliputi *id_produk*, *sku_internal*, *nama_produk*, *merek*, dan *kategori*. Guna menjamin integritas data, setiap SKU produk hanya tercatat sebanyak satu kali (*unique record*) pada tabel ini, di mana *id_produk* dialokasikan sebagai *Primary Key* (PK) yang menjadi acuan interkoneksi bagi tabel-tabel lainnya.

2. Tabel Transaksional (Turunan)

Kategori kedua terdiri dari empat tabel transaksional yang mencatat perkembangan data logistik dan hasil pemodelan secara berkala. Berbeda dengan tabel master, pada tabel transaksional ini satu produk dapat muncul berulang kali secara dinamis sesuai dengan deret periode waktu pengambilan data (*time-series*). Hubungan antartabel ini dengan tabel master

membentuk karakteristik kardinalitas *One-to-Many* (1 produk memiliki banyak baris data histori), di mana variabel *id_produk* diimplementasikan sebagai *Foreign Key* (FK).

Adapun rincian fungsi dari keempat tabel turunan tersebut adalah sebagai berikut:

- **T_Harga_Kompetitor:** Berfungsi untuk menampung data historis hasil *scraping* harga produk sejenis dari berbagai platform kompetitor yang telah diselaraskan per periode waktu berjalan.
- **T_Transaksi_Internal:** Berfungsi untuk mencatat histori performa penjualan internal perusahaan, yang mencakup variabel harga jual internal, Harga Pokok Penjualan (HPP) atau modal barang, serta volume permintaan produk per periode.
- **T_Feature_Engineering:** Merupakan tabel yang menyimpan variabel-variabel hasil rekayasa fitur (*derived features*) dari data transaksi internal dan kompetitor. Variabel di dalam tabel ini (seperti *lag volume*, *rolling mean 4-weeks*, *price gap*, *price ratio*, dan *margin feature*) digunakan sebagai pasokan data input utama untuk melatih model *machine learning*.
- **T_Optimasi_Harga:** Berfungsi sebagai tabel keluaran (*output layer*) dari sistem preskriptif, yang menyimpan hasil kalkulasi akhir model berupa nilai prediksi *demand*, rekomendasi batas HPP, serta saran harga optimal (*sweet spot price*) untuk mendukung keputusan manajemen.

5.4.6 Visualisasi Data (3 SKS)

Visualisasi data merupakan komponen yang diterapkan di dua lapisan dalam proyek ini. Pada lapisan eksplorasi dan analisis (*notebook*), dilakukan visualisasi berupa histogram distribusi *similarity score* hasil *product matching*, grafik batang *top brand* dengan jumlah pencocokan terbanyak, distribusi jumlah produk *match* per kompetitor, serta *scatter plot* perbandingan harga DB Klik dengan harga kompetitor, yang semuanya dihasilkan menggunakan *library* Matplotlib dan digunakan untuk menginterpretasikan pola data dan kualitas hasil analisis. Pada lapisan implementasi bisnis, dikembangkan dashboard interaktif menggunakan Looker Studio yang menampilkan KPI penjualan seperti total omset, total pelanggan, total produk terjual, biaya iklan, ACOS, serta analisis pertumbuhan (*growth rate*) per kategori dan per produk dalam bentuk grafik dan tabel yang dapat diperbarui secara berkala. Penggunaan teknik visualisasi yang tepat untuk menyampaikan informasi kepada audiens teknis maupun non-teknis ini secara langsung merepresentasikan kompetensi yang dikembangkan dalam mata kuliah Visualisasi Data (Sulaimain, et al 2024).

5.4.7 Manajemen Proyek (3 SKS)

Kegiatan studi independen ini dilaksanakan sebagai sebuah proyek dengan siklus kerja yang lengkap dan terstruktur, mulai dari tahap

perencanaan, pengumpulan dan integrasi data, pengembangan sistem, evaluasi, hingga *deployment* dan dokumentasi. Selama pelaksanaan, mahasiswa mengelola alur kerja proyek secara mandiri dengan memperhatikan prioritas tugas, ketergantungan antar tahapan (*task dependency*), serta penyelesaian masalah teknis yang muncul di setiap tahapan. Koordinasi juga dilakukan secara aktif dengan pihak perusahaan untuk memastikan data yang digunakan sesuai dengan kebutuhan bisnis, serta hasil yang dikembangkan relevan dan dapat diimplementasikan oleh pengguna akhir. Pengelolaan proyek yang mencakup perencanaan, pelaksanaan, pemantauan, dan penutupan ini secara langsung merepresentasikan kompetensi inti dalam mata kuliah Manajemen Proyek.

5.4.8 Pemrosesan Bahasa Alami (3 SKS)

Implementasi *Natural Language Processing* (NLP) merupakan salah satu inti teknis dari proyek ini, yang diterapkan secara langsung pada tahap *product matching* untuk menyelaraskan data produk internal CV DB Klik dengan data produk kompetitor. Proses NLP yang dilakukan mencakup tahapan *text preprocessing* (normalisasi huruf, penghapusan karakter khusus, *case folding*, dan standarisasi nama merek menggunakan kamus domain-spesifik), ekstraksi fitur teks menggunakan metode TF-IDF dengan pembobotan berdasarkan frekuensi dan keunikan kata, pembentukan konteks kata menggunakan pendekatan *N-Gram* (unigram dan bigram) untuk menangkap pola penulisan kode dan tipe produk elektronik, serta pengukuran tingkat kemiripan antara dua dokumen teks menggunakan *Cosine Similarity*.

Kombinasi metode NLP ini terbukti efektif dalam menangani inkonsistensi penamaan SKU pada data retail multi-platform, sebagaimana dikonfirmasi oleh Manning, Raghavan & Schütze (2008) bahwa pendekatan berbasis representasi vektor teks mampu menangani variasi linguistik pada data tidak terstruktur. Selain itu, penggunaan kamus *brand alias* untuk normalisasi nama merek juga merupakan salah satu bentuk pemanfaatan pengetahuan domain dalam pipeline NLP yang sejalan dengan pendekatan yang dikemukakan oleh Aggarwal (2018) terkait penggunaan leksikon domain-spesifik untuk meningkatkan akurasi pencocokan entitas teks. Keseluruhan implementasi NLP dalam proyek ini secara langsung merepresentasikan kompetensi inti yang dikembangkan dalam mata kuliah Pemrosesan Bahasa Alami (Kusniyati dan Nugraha, 2020).

BAB VI

RENCANA TINDAK LANJUT DAN REKOMENDASI

6.1 Rencana Tindak Lanjut

6.1.1 Pengembangan Produk atau Proyek

Hasil kegiatan Studi Independen yang telah dilaksanakan menghasilkan sebuah *prototype Decision Support System* untuk optimasi harga produk berbasis *Machine Learning* yang terintegrasi dengan proses *product matching*, prediksi permintaan, serta simulasi optimasi harga. Sebagai tindak lanjut, sistem yang telah dikembangkan dapat disempurnakan melalui pengembangan fitur yang lebih adaptif dan implementatif pada lingkungan bisnis nyata.

Pengembangan yang dapat dilakukan meliputi peningkatan akurasi proses *product matching* melalui pemanfaatan metode *Natural Language Processing* berbasis *transformer* atau *embedding models*, seperti BERT atau Sentence Transformer, untuk meningkatkan kemampuan identifikasi produk dengan variasi penulisan yang lebih kompleks. Selain itu, model prediksi permintaan dapat dikembangkan menggunakan pendekatan *Deep Learning* berbasis *time series forecasting*, seperti Long Short-Term Memory (LSTM) atau Temporal Fusion Transformer (TFT), sehingga mampu menangkap pola temporal dan perilaku pasar yang lebih dinamis.

Pada sisi optimasi harga, pengembangan selanjutnya dapat dilakukan dengan menerapkan metode optimasi berbasis *metaheuristic* atau *reinforcement learning* untuk menghasilkan strategi penetapan harga yang lebih adaptif terhadap perubahan kondisi pasar. Selain itu, sistem berbasis web yang telah dikembangkan juga dapat disempurnakan dengan penambahan fitur simulasi multi-skenario, rekomendasi strategi harga, serta integrasi data secara *real-time*.

6.1.2 Pelatihan dan Transfer Pengetahuan

Agar sistem yang telah dikembangkan dapat dimanfaatkan secara optimal, diperlukan proses transfer pengetahuan kepada pihak perusahaan, khususnya pada divisi yang terlibat dalam pengelolaan produk dan penetapan harga. Kegiatan transfer pengetahuan dapat dilakukan melalui pelatihan penggunaan dashboard monitoring, pelatihan interpretasi hasil prediksi dan optimasi harga, serta pendampingan penggunaan sistem simulasi harga berbasis web. Selain itu, dokumentasi teknis dan panduan penggunaan sistem perlu disusun secara komprehensif agar pengguna dapat mengoperasikan, memelihara, dan mengembangkan sistem secara mandiri tanpa ketergantungan pada pengembang awal.

6.1.3 Monitoring dan Evaluasi Berkala

Sebagai bentuk evaluasi keberlanjutan sistem, diperlukan mekanisme monitoring dan evaluasi secara berkala terhadap performa model prediksi dan sistem optimasi harga yang telah dibangun. Monitoring dapat dilakukan melalui pengukuran akurasi prediksi permintaan, evaluasi efektivitas rekomendasi harga, serta pengukuran peningkatan profitabilitas perusahaan setelah implementasi sistem. Selain evaluasi teknis, pengumpulan umpan balik (*feedback*) dari pengguna juga perlu dilakukan

untuk mengetahui tingkat kemudahan penggunaan sistem, kebutuhan pengembangan fitur baru, serta kendala operasional yang ditemukan selama implementasi. Hasil evaluasi tersebut dapat digunakan sebagai dasar perbaikan dan pengembangan sistem pada tahap berikutnya.

6.1.4 Pengajuan Pendanaan atau Kerja Sama

Pengembangan sistem *Price Optimization* berbasis *Machine Learning* memiliki potensi untuk diimplementasikan secara lebih luas pada industri retail dan e-commerce. Oleh karena itu, diperlukan peluang kerja sama lanjutan antara institusi pendidikan, mitra industri, serta pihak lain yang relevan guna mendukung pengembangan sistem pada skala yang lebih besar. Selain itu, pengajuan pendanaan penelitian maupun pengembangan produk dapat dilakukan untuk mendukung peningkatan infrastruktur, integrasi data *real-time*, pengembangan model kecerdasan buatan yang lebih kompleks, serta implementasi sistem pada berbagai sektor industri lainnya.

6.2 Rekomendasi

6.2.1 Rekomendasi Teknis

Berdasarkan hasil pelaksanaan proyek, terdapat beberapa rekomendasi teknis yang dapat dilakukan untuk meningkatkan performa sistem. Pertama, proses *product matching* dapat ditingkatkan dengan memanfaatkan metode *semantic similarity* berbasis *deep learning* untuk mengurangi potensi *false matching*. Kedua, model prediksi permintaan dapat dikembangkan dengan membandingkan performa beberapa algoritma *machine learning* dan *deep learning* guna memperoleh model yang lebih optimal. Ketiga, proses optimasi harga dapat diperluas dengan mempertimbangkan faktor eksternal lain, seperti tren pasar, promosi, musim, dan perilaku konsumen. Selain itu, integrasi data secara otomatis dan *real-time* juga direkomendasikan untuk meningkatkan kemampuan sistem dalam menghasilkan rekomendasi harga yang lebih adaptif terhadap perubahan kondisi pasar.

6.2.2 Rekomendasi Manajerial dan Operasional

Perusahaan disarankan untuk mengimplementasikan pendekatan *data-driven decision making* dalam proses penentuan harga produk sehingga keputusan bisnis tidak hanya didasarkan pada intuisi atau pengalaman, tetapi juga mempertimbangkan hasil analisis data secara objektif. Selain itu, diperlukan pengelolaan data yang lebih terstruktur, termasuk standarisasi penamaan produk, pengelolaan database kompetitor, serta dokumentasi histori penjualan yang konsisten.

Penerapan sistem optimasi harga juga memerlukan kolaborasi yang baik antara divisi bisnis, pemasaran, dan teknologi informasi agar rekomendasi yang dihasilkan dapat diimplementasikan secara efektif sesuai dengan kebutuhan operasional perusahaan.

6.2.3 Rekomendasi Kebijakan dan Strategis

Perusahaan dapat mempertimbangkan pengembangan sistem pendukung keputusan berbasis kecerdasan buatan sebagai bagian dari strategi transformasi digital perusahaan. Implementasi sistem analitik dan optimasi berbasis data diharapkan mampu meningkatkan daya saing perusahaan, mempercepat proses pengambilan keputusan, serta

meningkatkan efisiensi operasional dalam jangka panjang. Selain itu, pengembangan kebijakan terkait pengelolaan data dan pemanfaatan teknologi analitik juga diperlukan untuk mendukung implementasi sistem secara berkelanjutan.

6.2.4 Rekomendasi Pengembangan Ilmu dan Penelitian Lanjutan

Penelitian selanjutnya dapat difokuskan pada pengembangan model prediksi permintaan dan optimasi harga yang lebih kompleks dengan memanfaatkan pendekatan *deep learning*, *reinforcement learning*, maupun metode optimasi berbasis *metaheuristic*. Selain itu, penelitian mengenai integrasi *real-time pricing*, analisis elastisitas harga, serta pemanfaatan data eksternal seperti tren pasar, media sosial, dan perilaku konsumen juga dapat menjadi topik penelitian yang potensial. Pengembangan penelitian lanjutan tersebut diharapkan mampu menghasilkan sistem optimasi harga yang lebih adaptif, akurat, dan relevan dengan dinamika pasar digital yang terus berkembang.

BAB VII

KESIMPULAN DAN REFLEKSI DIRI

7.1 Kesimpulan

Berdasarkan pelaksanaan kegiatan Studi Independen di CV DB Klik, dapat disimpulkan bahwa pengembangan sistem *Price Optimization* berbasis *Machine Learning* berhasil dilaksanakan mulai dari tahap pengumpulan data, *product matching*, *feature engineering*, prediksi permintaan, optimasi harga, hingga implementasi sistem berbasis web dan dashboard monitoring. Sistem yang dikembangkan berhasil mengintegrasikan data internal perusahaan dan data eksternal kompetitor untuk menghasilkan rekomendasi harga yang lebih adaptif dan berbasis data.

Pada tahap *product matching*, penerapan pendekatan *Natural Language Processing* menggunakan kombinasi metode TF-IDF, N-Gram, dan Cosine Similarity berhasil digunakan untuk menyelaraskan produk internal dengan produk kompetitor yang memiliki perbedaan format penulisan. Pendekatan tersebut terbukti efektif dalam menangani data teks tidak terstruktur pada lingkungan e-commerce dan retail digital (Manning et al., 2008; Aggarwal, 2018). Hasil *matching* yang diperoleh kemudian digunakan sebagai dasar dalam pembentukan fitur kompetitif dan analisis pasar.

Pada tahap prediksi permintaan, algoritma *Random Forest Regression* berhasil diimplementasikan untuk mempelajari hubungan antara variabel internal perusahaan, kondisi pasar, serta karakteristik kompetitor terhadap permintaan produk. Penggunaan *Random Forest* dipilih karena memiliki kemampuan yang baik dalam menangani hubungan non-linear dan menghasilkan performa prediksi yang stabil pada data retail yang kompleks (Breiman, 2001; Hossain, 2025). Selanjutnya, hasil prediksi permintaan tersebut diintegrasikan ke dalam proses simulasi optimasi harga sehingga sistem mampu menghasilkan rekomendasi harga yang mempertimbangkan perubahan permintaan, profitabilitas, serta kondisi persaingan pasar.

Selain menghasilkan model prediksi dan optimasi, kegiatan studi independen ini juga berhasil menghasilkan sebuah *prototype Decision Support System* berbasis web yang dibangun menggunakan HTML, CSS, JavaScript, Python, dan FastAPI, serta dilengkapi dengan dashboard monitoring menggunakan Looker Studio. Dengan demikian, hasil kegiatan ini tidak hanya memberikan kontribusi akademis, tetapi juga menghasilkan solusi yang aplikatif untuk mendukung proses pengambilan keputusan berbasis data pada industri retail teknologi informasi.

7.2 Refleksi Akhir

Pelaksanaan Studi Independen di CV DB Klik memberikan pengalaman yang sangat berharga dalam menerapkan ilmu yang telah dipelajari selama perkuliahan ke dalam permasalahan nyata di dunia industri. Selama proses pengembangan sistem, penulis memperoleh pemahaman bahwa pembangunan sebuah sistem *data-driven decision support* tidak hanya berfokus pada pembangunan model *machine learning*, tetapi juga melibatkan proses pengumpulan data, integrasi data, validasi kualitas data, hingga implementasi sistem yang dapat digunakan secara langsung oleh pengguna.

Pengalaman dalam melakukan integrasi data dari berbagai sumber, proses *product matching* menggunakan pendekatan *Natural Language Processing*, pembangunan model prediksi permintaan menggunakan *Random Forest Regression*, serta pengembangan sistem berbasis web memberikan wawasan baru

mengenai kompleksitas penerapan *data science* di lingkungan industri. Selain itu, proses evaluasi, perbaikan model, dan pengujian sistem secara berulang juga memberikan pemahaman bahwa keberhasilan suatu sistem analitik sangat dipengaruhi oleh kualitas data, pemilihan metode yang tepat, serta kemampuan dalam menerjemahkan kebutuhan bisnis ke dalam solusi teknologi.

Kegiatan studi independen ini juga memberikan kesempatan kepada penulis untuk mengembangkan kemampuan teknis maupun non-teknis, seperti *problem solving*, *critical thinking*, komunikasi, manajemen proyek, serta kemampuan beradaptasi terhadap kebutuhan industri yang dinamis. Pengalaman tersebut menjadi bekal yang sangat berharga untuk pengembangan karier di bidang *Data Science*, *Machine Learning*, maupun *Business Analytics* di masa yang akan datang.

Secara keseluruhan, pelaksanaan Studi Independen ini memberikan pengalaman nyata mengenai bagaimana teknologi *Artificial Intelligence*, *Machine Learning*, dan *Business Analytics* dapat diintegrasikan untuk menghasilkan solusi yang tidak hanya memiliki nilai akademis, tetapi juga memberikan dampak praktis dan strategis bagi dunia industri. Pengalaman ini sekaligus memperkuat pemahaman penulis bahwa pendekatan *data-driven decision making* merupakan salah satu faktor penting dalam mendukung transformasi digital dan peningkatan daya saing perusahaan di era modern (Provost & Fawcett, 2013; Liu & Sustik, 2021).

DAFTAR PUSTAKA

Aggarwal, C.C. (2018) *Machine Learning for Text*. Cham: Springer International Publishing. Available at: <https://doi.org/10.1007/978-3-319-73531-3>.

Basu, R., Aktar, Md.N. and Kumar, S. (2025) 'The interplay of artificial intelligence, machine learning, and data analytics in digital marketing and promotions: a review and research agenda', *Journal of Marketing Analytics*, 13(2), pp. 267–287. Available at: <https://doi.org/10.1057/s41270-024-00355-6>.

Breiman, L. (2001) 'Random forests', *Machine Learning*, 45(1), pp. 5–32.

Defit, S. and Widi Nurcahyo, G. (no date) 'Product codification accuracy with cosine similarity and weighted term frequency and inverse document frequency (TF-IDF)', *Journal of Applied Engineering and Technological Science* [Preprint].

Fawcett, T. and Provost, F. (2013) *Data Science for Business*. Sebastopol, CA: O'Reilly Media.

Ferreira, K.J., Lee, H.A. and Simchi-Levi, D. (no date) 'Analytics for an online retailer: demand forecasting and price optimization'. Available at: www.ruelala.com.

Ganguly, P. and Mukherjee, I. (2024) 'Enhancing retail sales forecasting with optimized machine learning models', in *2024 4th International Conference on Sustainable Expert Systems (ICSSES)*. IEEE, pp. 884–889. Available at: <https://doi.org/10.1109/ICSSES63445.2024.10762950>.

Hossain, Q. et al. (2024) 'Leveraging business analytics to optimize retail merchandizing strategies: a data driven approach', *Journal of Information Systems Engineering and Management*. Available at: <https://www.jisem-journal.com>.

Hyndman, R.J. and Athanasopoulos, G. (2021) *Forecasting: Principles and Practice*. 3rd edn. Melbourne: Monash University. Available at: <https://otexts.com/fpp3/> (Accessed: 1 July 2026).

Iskandar, P. et al. (2024) 'Optimizing retail pricing through random forest regression: a machine learning approach for dynamic pricing', in *2024 International Conference on ICT for Smart Society (ICIMCIS)*, pp. 637–642. Available at: <https://doi.org/10.1109/ICIMCIS63449.2024.10956465>.

Jurafsky, D. and Martin, J.H. (2023) *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*. 3rd edn. Draft manuscript. Stanford University. Available at: <https://web.stanford.edu/~jurafsky/slp3/> (Accessed: 1 July 2026).

Kaur, H., Pannu, H.S. and Malhi, A.K. (2019) 'A systematic review on imbalanced data challenges in machine learning: applications and solutions', *ACM Computing Surveys*, 52(4). Available at: <https://doi.org/10.1145/3343440>.

Khatib Sulaiman, J., Asher, J. and Putri Rachmawati, E. (no date) 'Visualisasi data operasi SAR BASARNAS di Indonesia menggunakan Google Looker Studio', *Indonesian Journal of Computer Science* [Preprint].

Kimball, R. and Ross, M. (2013) *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. 3rd edn. Indianapolis, IN: John Wiley & Sons.

Kusniyati, H. and Nugraha, A. (2020) 'Analysis of matrix product matching between cosine similarity with term frequency-inverse document frequency (TF-IDF) and Word2Vec in PT. Pricebook Digital Indonesia', *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*, pp. 105–112. Available at: <https://doi.org/10.32628/CSEIT195672>.

Liu, C. and Sustik, M.A. (2021) 'Elasticity based demand forecasting and price optimization for online retail' [Preprint]. Available at: <http://arxiv.org/abs/2106.08274>.

Manning, C.D., Raghavan, P. and Schütze, H. (2008) *Introduction to Information Retrieval*. Cambridge: Cambridge University Press.

Phillips, R.L. (2005) *Pricing and Revenue Optimization*. Stanford, CA: Stanford University Press.

Rahman, K.O. and Hasan, M. (2025) 'AI-driven next-gen U.S. retail: an empirical study on optimizing supply chains by leveraging artificial intelligence, business intelligence, and machine learning', *Journal of Computer Science and Technology Studies*. Available at: <https://doi.org/10.32996/jests>.

Ramírez, S. (2021) *FastAPI: High Performance, Easy to Learn, Fast to Code, Ready for Production*. FastAPI Documentation. Available at: <https://fastapi.tiangolo.com/>.

Salton, G. and Buckley, C. (1988) 'Term-weighting approaches in automatic text retrieval', *Information Processing & Management*, 24(5), pp. 513–523. Available at: [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0).

Schonlau, M. and Zou, R.Y. (2020) 'The random forest algorithm for statistical learning', *Stata Journal*, 20(1), pp. 3–29. Available at: <https://doi.org/10.1177/1536867X20909688>.

Scornet, E., Biau, G. and Vert, J.P. (2015) 'Consistency of random forests', *Annals of Statistics*, 43(4), pp. 1716–1741. Available at: <https://doi.org/10.1214/15-AOS1321>.

Talluri, K.T. and Van Ryzin, G.J. (2005) *The Theory and Practice of Revenue Management*. New York: Springer Science + Business Media.

LAMPIRAN

2. Website Simulasi yang sudah di-deployment
<https://dbklik-price-optimization.netlify.app/>
3. Source code dan data yang dihasilkan
 - Github : Berisi code pemrograman sistem website simulasi
<https://github.com/nurinsalsabl/dbklik-price-optimization>
 - Google Drive : Berisi data-data yang diperlukan dan notebook google colab
https://drive.google.com/drive/folders/1BPQDivibzN1p31VsZ1f6E77svdjap2jk?usp=drive_link
4. Dokumentasi kegiatan selama studi independen

